

	FORMULIR	Nomor Agenda : _____
	PERSETUJUAN LAPORAN TUGAS AKHIR POLITEKNIK SIBER DAN SANDI NEGARA (FO-022-PTI.2022)	Berlaku Sejak : 08 Juli 2025
		Revisi : 1
		Halaman : 1

Nama Mahasiswa : Muhammad Aqil Nuur Al-Farabi
 NPM : 2221101817
 Jurusan : Rekayasa Kriptografi
 Program Studi : Rekayasa Sistem Kriptografi
 Bidang Minat : Rekayasa Perangkat Lunak Kripto
 Tahun Akademik : 2025/2026
 Judul Tugas Akhir : Implementasi Asisten Cerdas Berbasis Retrieval Augmented Generation dengan Studi Kasus Peraturan SPBE di PUSDATIK BSSN

Dinyatakan telah menyelesaikan penulisan **Laporan 70% / 100%*** Tugas Akhir dan dokumen yang terlampir pada formulir ini telah disetujui untuk dikumpulkan sebagai persyaratan mengikuti **Seminar/Sidang*** Tugas Akhir Politeknik Siber dan Sandi Negara tahun ajaran 2025/2026

Bogor, 5 Juni 2026

Dosen Pembimbing TA



R Budiarto Hadiprakoso, MMSI
 NIP. 198610172017121001

*)Coret yang tidak perlu

**Dokumen ini telah ditandatangani secara elektronik menggunakan sertifikat elektronik yang diterbitkan oleh Balai Besar Sertifikasi Elektronik (BsrE), Badan Siber dan Sandi Negara.

TUGAS AKHIR



Implementasi Asisten Cerdas Berbasis Retrieval Augmented Generation dengan Studi Kasus Peraturan SPBE di PUSDATIK BSSN

Muhammad Aqil Nuur Al-Farabi
22211011817

Rekayasa Kriptografi
Politeknik Siber dan Sandi Negara
2026

TUGAS AKHIR

Diajukan untuk memenuhi persyaratan menyelesaikan pendidikan Diploma IV pada
Politeknik Siber dan Sandi Negara



Implementasi Asisten Cerdas Berbasis Retrieval Augmented *Generation* dengan Studi Kasus Peraturan SPBE di PUSDATIK BSSN

Muhammad Aqil Nuur Al-Farabi
2221101817

Rekayasa Kriptografi
Politeknik Siber dan Sandi Negara
2026

LEMBAR PERSETUJUAN

Proposal Tugas Akhir dengan:

JUDUL : Implementasi Asisten Cerdas Berbasis Retrieval Augmented
Generation dengan Studi Kasus Peraturan SPBE di PUSDATIK
BSSN

PENULIS : Muhammad Aqil Nuur Al-Farabi

NPM : 2221101817

dinyatakan telah sesuai dengan Berita Acara Seminar Tugas Akhir dan disetujui untuk digunakan sebagai syarat menyelesaikan pendidikan di Politeknik Siber dan Sandi Negara Angkatan 2022 tahun 2026.

Bogor, 5 Juni 2026

Pembimbing Materi



R Budiarto Hadiprakoso, MMSI
NIP. 198610172017121001

Dokumen ini telah ditandatangani secara elektronik menggunakan sertifikat elektronik yang diterbitkan oleh Balai Sertifikasi Elektronik (BSrE), Badan Siber dan Sandi Negara

LEMBAR PENGESAHAN

Proposal Tugas Akhir dengan:

JUDUL : Implementasi Asisten Cerdas Berbasis Retrieval Augmented
Generation dengan Studi Kasus Peraturan SPBE di PUSDATIK
BSSN

PENULIS : Muhammad Aqil Nuur Al-Farabi

NPM : 2221101817

telah diperiksa dan disahkan oleh Tim Penguji Seminar Tugas Akhir di Bogor, pada
tanggal 11 Juni 2026

Ketua Penguji




Girinoto, S.Si., M.Si.
NIP 197701092005011006

Penguji I



R Budiarto Hadiprakoso, MMSI
NIP 198610172017121001

Penguji II



Hermawan Setiawan, S.Si., M.TI.
NIP 197406231993121001

Dokumen ini telah ditandatangani secara elektronik menggunakan sertifikat elektronik yang
diterbitkan oleh Balai Sertifikasi Elektronik (BSrE), Badan Siber dan Sandi Negara

ABSTRAK

Implementasi Asisten Cerdas Berbasis Retrieval Augmented *Generation* dengan Studi Kasus Peraturan SPBE di PUSDATIK BSSN

oleh

Muhammad Aqil Nuur Al-Farabi
2221101817

Rekayasa Kriptografi

Dokumen regulasi Sistem Pemerintahan Berbasis Elektronik (SPBE) memiliki sifat yang kompleks, bersifat hierarkis, serta saling merujuk dan berhubungan antar peraturan satu dengan yang lain. Hal ini menuntut pemahaman kontekstual yang tinggi dalam proses evaluasi dan audit. Permasalahan tersebut menjadi tantangan nyata bagi pegawai yang terlibat dalam proses evaluasi SPBE di lingkungan BSSN, khususnya personel baru pada unit-unit kerja yang bertanggung jawab atas pengumpulan data dukung SPBE. Proses yang masih dilakukan secara manual ini berpotensi menimbulkan inkonsistensi dalam penyusunan data dukung evaluasi SPBE.

Penelitian ini bertujuan untuk mengembangkan dan mengevaluasi sebuah sistem *Retrieval-Augmented Generation* (RAG) yang dirancang khusus untuk mendukung pemahaman dan penelusuran regulasi SPBE di lingkungan BSSN dengan PUSDATIK sebagai pengelola layanan. Metode yang digunakan adalah *Design Science Research Methodology* (DSRM), dengan tahapan perancangan, pengembangan, demonstrasi, dan evaluasi artefak berupa sistem *chatbot* berbasis *Large Language Model* (LLM).

Evaluasi kualitas jawaban RAG dilakukan menggunakan *Framework Retrieval Augmented Generation Assessment* (RAGAS) dengan fokus pada metrik *faithfulness*, *answer relevance*, *context precision*, dan *context recall*. Kemudian terdapat penerapan JWT sebagai lapisan keamanannya, dilanjutkan pada kepuasan pengguna yang dievaluasi menggunakan *Chatbot Usability Scale* (BUS-11). Beberapa penelitian mengungkapkan bahwa sistem asisten cerdas berbasis RAG mampu menghasilkan jawaban yang akurat, relevan, dan konsisten pada regulasi SPBE disertai tingkat kepuasan yang baik pula.

xii + 68 halaman + 17 halaman lampiran (2026)

Kata kunci : Retrieval-Augmented *Generation* (1) , Asisten Cerdas (2), SPBE (3), *Chatbot* Pemerintahan (4), Evaluasi RAG (5)

DAFTAR ISI

	Halaman
LEMBAR PENGESAHAN	4
ABSTRAK	5
DAFTAR ISI	6
DAFTAR GAMBAR	9
DAFTAR TABEL	10
DAFTAR LAMPIRAN	11
BAB I PENDAHULUAN	12
I.1 LATAR BELAKANG	12
I.2 RUMUSAN MASALAH	15
I.3 PEMBATASAN MASALAH	15
I.4 TUJUAN DAN MANFAAT	16
I.4.1 Tujuan	Error! Bookmark not defined.
I.4.2 Manfaat	16
I.5 SISTEMATIKA PENULISAN	16
BAB II TELAAH KEPUSTAKAAN	18
II.1 LANDASAN TEORI	18
II.1.1 Sistem Pemerintah Berbasis Elektronik (SPBE)	18
II.1.2 Asisten Cerdas Berbasis LLM (Large Language Models)	19
II.1.3 Retrieval Augmented <i>Generation</i> (RAG)	20
II.1.4 JSON Web Token (JWT)	23
II.1.5 Pengukuran <i>Chatbot</i>	24
II.2 PENELITIAN TERKAIT	29
II.3 KERANGKA KONSEPTUAL	34
BAB III METODOLOGI PENELITIAN	35
III.1 OBJEK PENELITIAN	35
III.2 JENIS PENELITIAN	35
III.3 DESAIN PENELITIAN	35
III.3.1 <i>Problem Identification and Motivation</i>	36
III.3.2 <i>Define the Objectives for a Solution</i>	37

III.3.3	<i>Design and Development</i>	37
III.3.4	<i>Demonstration</i>	40
III.3.5	<i>Evaluation</i>	40
III.3.6	<i>Communication</i>	41
BAB IV 42		
IV.1	DESIGN AND DEVELOPMENT.....	42
IV.1.1	Arsitektur Sistem	42
IV.1.2	Pembentukan <i>Knowledge base</i>	43
IV.1.2.1	Pengumpulan Dokumen.....	43
IV.1.2.2	<i>Document Ingestion Interface</i>	44
IV.1.2.3	<i>Upload</i> dan menyimpan metadata	46
IV.1.2.4	Strategi <i>Chunking</i>	46
IV.1.2.5	<i>Indexing</i> ke Qdrant dan BM25.....	48
IV.1.2.6	Sinkronisasi dan Penghapusan Dokumen	49
IV.1.3	Implementasi Autentikasi, Otorisasi, dan Audit Logging	50
IV.1.3.1	Alur <i>Login</i> dan Pemilihan Provider.....	51
IV.1.3.2	Pembentukan <i>Access Token</i> dan <i>Refresh Token</i>	52
IV.1.3.3	<i>Refresh Token</i> Rotation	53
IV.1.3.4	Pencabutan Token.....	54
IV.1.3.5	Otorisasi Berdasarkan <i>Role</i> Pengguna.....	55
IV.1.3.6	<i>Logout</i>	56
IV.1.3.7	Audit Logging.....	57
IV.1.4	Implementasi Autentikasi, Otorisasi, dan Audit Logging	58
IV.1.4.1	Arsitektur <i>RAG Engine</i>	58
IV.1.4.2	Penerimaan Pertanyaan dan Session Handling.....	59
IV.1.4.3	Klasifikasi Pertanyaan	60
IV.1.4.4	Query Expansion.....	61
IV.1.4.5	<i>Hybrid Retrieval</i>	62
IV.1.4.6	Reciprocal Rank Fusion dan Reranking	63
IV.1.4.7	<i>Context Stitching</i> dan Penyusunan Sumber	64
IV.1.4.8	<i>Prompt Construction</i> dan <i>Generation</i> oleh LLM	65
IV.1.4.9	Validasi Sitasi dan <i>Quality Report</i>	67

IV.1.5 Implementasi Antarmuka Pengguna.....	67
IV.2 Demonstration.....	69
IV.2.1 Lingkungan Demonstrasi.....	69
IV.2.2 Demonstrasi Pengguna	70
IV.2.3 Demonstrasi Administrator.....	71
IV.3 EVALUATION.....	72
DAFTAR PUSTAKA	75
Lampiran	84
DAFTAR RIWAYAT HIDUP.....	99

DAFTAR GAMBAR

Gambar 2. 1 Jenis pendekatan RAG [8].....	21
Gambar 2. 2 Skema <i>lifecycle</i> dari JWT [36]	24
Gambar 2. 3 Kerangka Konseptual	34
Gambar 3. 1 <i>Design Science Research Methodology process model</i> [42].....	36
Gambar 3.2 Konsep alur <i>chatbot</i>	39
Gambar 4.1 Arsitektur sistem.....	42
Gambar 4.2 Tahapan Pembentukan <i>Knowledge base</i>	43
Gambar 4.3 Fungsi <i>Upload</i> , <i>preview</i> , dan <i>save document</i>	45
Gambar 4.4 Fungsi daftar, sinkronisasi, dan hapus dokumen.....	45
Gambar 4.5 Fungsi <i>Upload</i> dan Menyimpan Metadata	46
Gambar 4.6 Fungsi <i>chunk_document</i>	47
Gambar 4.7 Fungsi <i>Preview Chunks</i>	47
Gambar 4.8 Fungsi <i>index_document</i>	48
Gambar 4.9 <i>Payload Metadata</i>	49
Gambar 4.10 Fungsi <i>delete_document</i>	50
Gambar 4.11 Proses <i>Login</i>	52
Gambar 4.12 Alur Pembentukan Token Setelah <i>Login</i>	53
Gambar 4.13 Alur <i>refresh</i> token rotation.....	54
Gambar 4.14 Alur pemeriksaan <i>role</i> pengguna	56
Gambar 4.15 Alur <i>logout</i> sistem	57
Gambar 4.16 Arsitektur RAG	59
Gambar 4.17 Laman <i>chat</i> pengguna	60
Gambar 4.18 Alur klasifikasi pertanyaan.....	61
Gambar 4.19 <i>Hybrid retrieval</i> pada RAG.....	62
Gambar 4.20 Alur <i>reciprocal rank fusion</i> dan <i>reranking</i>	64
Gambar 4.21 lampiran dari penyusunan sumber jawaban	65
Gambar 4.22 Alur <i>prompt construction</i> dan <i>generation</i> oleh LLM	66

DAFTAR TABEL

	Halaman
Tabel 2.1 Struktur Faktor dan Poin BUS-11 [14]	27
Tabel 2.2 Skor Bus-11 [14].....	28
Tabel 2.3 Penelitian terkait	31
Tabel 3.1 Komponen RAG.....	37
Tabel 4.1 Daftar hasil pengumpulan dokumen.....	43
Tabel 4.2 Ringkasan Mekanisme Autentikasi dan Otorisasi	51
Tabel 4.3 Jenis Token pada Sistem.....	53
Tabel 4.4 Kondisi Token dan Respons Sistem	55
Tabel 4.5 Contoh Pembatasan Hak Akses	55
Tabel 4.6 Event Audit pada Mekanisme Autentikasi.....	57
Tabel 4.7 Kategori pertanyaan pada RAG	61
Tabel 4.8 Contoh <i>Query Expansion</i>	62
Tabel 4.9 Metode <i>retrieval</i> pada RAG.....	63
Tabel 4.10 Hasil Penyusunan Konteks	65
Tabel 4.11 Komponen <i>quality report</i>	67
Tabel 4.12 Ringkasan Implementasi Antarmuka Pengguna	68
Tabel 4.13 Lingkungan Demonstrasi Sistem	70
Tabel 4.14 Demonstrasi Pengguna.....	70
Tabel 4.15 Demonstrasi Pengelolaan Knowledge Base.....	72
Tabel 4.16 Ringkasan Dataset Evaluasi RAG.....	73

DAFTAR LAMPIRAN

	Halaman
Lampiran 1	85
Lampiran 2	86
Lampiran 3	94

BAB I

PENDAHULUAN

I.1 LATAR BELAKANG

Pemahaman mengenai kepatuhan terhadap regulasi hukum merupakan tantangan yang krusial dan fundamental dalam tata kelola organisasi saat ini [1]. Dokumen regulasi peraturan umumnya memiliki isi yang kompleks, dengan struktur bahasa yang kaku, jumlah pasal yang masif, serta referensi antar aturan yang rumit. Saat ini, proses penelusuran dan interpretasi hukum masih bergantung pada keahlian manusia secara manual [2]. Ketergantungan ini akan menciptakan hambatan berupa waktu yang terbuang sia-sia, pemahaman yang berbeda-beda, dan risiko kesalahan manusia itu sendiri ketika jumlah dokumen yang dibaca dan dianalisis terus meningkat [3].

Salah satu domain yang memiliki kebijakan bersifat kompleks, berlapis, dan terus berkembang adalah domain Sistem Pemerintahan Berbasis Elektronik (SPBE) [2]. Dokumen regulasi SPBE tidak hanya panjang dan hierarkis, tetapi juga saling merujuk peraturan satu sama lain dan memerlukan konsistensi interpretasi yang memerlukan waktu dan personel yang cukup [4]. Kondisi ini menjadi tantangan tersendiri bagi unit kerja di BSSN, mengingat tantangan penyebaran pengetahuan domain SPBE kepada seluruh pengguna internal sering kali terkendala karena personel internal belum memiliki pemahaman mendalam mengenai konteks dan hierarki regulasi tersebut. Keterbatasan ini menghambat proses transfer pengetahuan yang efektif, sehingga meningkatkan risiko ketidakkonsistenan dalam interpretasi regulasi jika tidak dibantu oleh instrumen pendukung yang memadai.

Pusat Data dan Teknologi Informasi Komunikasi (PUSDATIK) merupakan unsur pendukung tugas dan fungsi BSSN yang berada di bawah dan bertanggung jawab kepada Kepala melalui Sekretaris Utama. Tugas utamanya adalah melaksanakan perencanaan, pelaksanaan, evaluasi, dan pelaporan di bidang data dan teknologi informasi komunikasi. Secara rinci, tugas pokok fungsi Pusat Data dan Teknologi Informasi Komunikasi sebagaimana tertuang dalam Pasal 105 Peraturan BSSN Nomor 6 Tahun 2021 mencakup perencanaan TIK hingga penyelenggaraan pusat data. Dalam penelitian ini, PUSDATIK ditempatkan sebagai pengelola sistem karena dia berada pada lingkungan layanan internal BSSN dan menjadi kanal strategis untuk integrasi layanan pengetahuan. Tantangan utama yang diangkat adalah penyediaan *chatbot* berbasis AI agar pegawai internal dapat memperoleh penjelasan regulasi SPBE secara cepat, konsisten, dan aman [6].

Untuk mengatasi tantangan tersebut, perkembangan teknologi kecerdasan buatan Large Language Model (LLM) menawarkan pendekatan baru yang mampu

mengotomasi proses pencarian dan interpretasi informasi berbasis dokumen. Namun, penerapan LLM standar tanpa diberikan peningkatan atau pemutakhiran rentan terhadap pemberian informasi yang salah. Pendekatan *Retrieval-Augmented Generation* (RAG) mampu memitigasi hal ini dengan membatasi jawaban atau keluaran AI terhadap konteks dokumen yang benar [7]. RAG merupakan sebuah paradigma yang meningkatkan kemampuan LLM dengan cara mengambil data (*retrieval*) dari basis pengetahuan eksternal yang relevan sebelum menghasilkan jawaban [8]. Namun, beberapa penelitian menunjukkan bahwa RAG konvensional atau *naive* RAG bersifat linier. Hal ini menyebabkan sistem belum mampu menjawab pertanyaan kompleks dan rentan terhadap halusinasi model meskipun dokumen rujukannya tersedia [9]. *Naive* RAG sering memperlakukan dokumen sebagai potongan teks yang datar, mengabaikan struktur hierarkis, hubungan sebab akibat, dan evolusi waktu, hal ini menyebabkan sistem gagal memberikan jawaban yang benar secara historis, misalnya tidak bisa membedakan beberapa topik peraturan SPBE yang lama dengan versi saat ini [10]. Alur *retrieve-and-generate* yang bersifat statis pada RAG tradisional tidak memadai untuk menangani kueri kompleks yang menuntut penalaran bertahap serta pengumpulan informasi yang adaptif. Oleh karena itu, diperlukan pendekatan RAG yang lebih kompleks namun tetap tidak mengorbankan performa sistem yang dikombinasikan dengan antarmuka yang tepat. Selain itu, tanpa mekanisme validasi respons, sistem RAG berpotensi menghasilkan jawaban yang menyimpang dari domain SPBE atau mengandung informasi yang tidak dapat dipertanggungjawabkan. Oleh karena itu, diperlukan lapisan *response validation* sebagai pengaman tambahan untuk memastikan keluaran sistem tetap berada dalam batas domain yang telah ditentukan [1]. Sebagai antarmuka interaksi, *chatbot* dipilih karena kebutuhan pengguna terhadap informasi regulasi SPBE bersifat kontekstual dan tidak selalu terstruktur. Berbeda dengan *search engine* yang hanya mengembalikan dokumen mentah, *chatbot* berbasis RAG memungkinkan pengguna berinteraksi secara dialogis mengajukan pertanyaan dalam bahasa natural, mempersempit konteks secara iteratif, dan mendapatkan jawaban yang sudah diinterpretasikan sesuai kebutuhan spesifik mereka [11].

Selain arsitektur sistem yang kompleks, pengembangan sistem asisten cerdas di lingkungan pemerintahan memerlukan standar validasi yang ketat dari segi kualitas jawaban asisten cerdas ataupun pengalaman pengguna. *Framework* evaluasi otomatis *Retrieval Augmented Generation Assessment* (RAGAS) dirancang khusus untuk mengukur kinerja *pipeline* RAG tanpa memerlukan validasi manusia yang ekstensif pada setiap pengujian [12]. RAGAS mampu mengukur *faithfulness* yaitu kesesuaian jawaban terhadap konteks yang ada dan *answer relevance* yaitu relevansi jawaban terhadap pertanyaan, keduanya merupakan poin yang sangat penting dalam domain hukum untuk meminimalkan risiko informasi yang salah [13]. Selain itu, pada evaluasi *conversational interface* memerlukan pendekatan yang berbeda dari RAGAS karena hanya mengukur bagian teknisnya saja. *Chatbot*

Usability Scale (BUS-11) digunakan sebagai instrumen terstandar untuk mengukur kepuasan pengguna secara komprehensif, mencakup lima faktor utama, yaitu aksesibilitas, kualitas fungsi, kualitas percakapan, privasi/keamanan, dan waktu respons [14]. Penggunaan BUS-11 dinilai relevan untuk menjelaskan kualitas interaksi antara pengguna internal BSSN dengan *chatbot* pengetahuan SPBE [15].

Namun, kualitas jawaban sistem saja tidak cukup jika sistem tidak dilindungi dari akses yang tidak sah. Mengingat *chatbot* ini akan digunakan di lingkungan internal BSSN, diperlukan mekanisme autentikasi yang andal. Berdasarkan hasil wawancara, sistem mensyaratkan mekanisme kontrol akses berbasis peran yang terhubung dengan *Active Directory*, di mana setiap pengguna diwajibkan melakukan autentikasi menggunakan token digital [35]. Mekanisme autentikasi berbasis JSON Web Token (JWT) dipilih karena kemampuannya menyediakan verifikasi identitas yang *stateless*, skalabel, dan aman untuk lingkungan API [35]. JWT memungkinkan *server* memverifikasi identitas dan permintaan pengguna tanpa menyimpan sesi di sisi *server*, sehingga sangat sesuai untuk lingkungan deployment internal yang dikelola PUSDATIK, di mana efisiensi sumber daya komputasi dan perlindungan terhadap data SPBE yang bersifat sensitif menjadi prioritas utama dalam tata kelola keamanan sistem. Di sisi lain, sistem yang diakses melalui jaringan internal tetap memerlukan *rate limiting* untuk mencegah percobaan permintaan akses tidak sah yang dapat melumpuhkan layanan *server*, serta risiko *request timeout* yang dapat menurunkan jalannya *system* [37]. Penerapan mekanisme *rate limiting* pada *endpoint* API *chatbot* menjadi lapisan pertahanan krusial untuk menjaga ketersediaan layanan dan mencegah penyalahgunaan sistem.

Oleh karena itu, penelitian ini mengusulkan pengembangan sistem asisten cerdas berbasis *Retrieval-Augmented Generation* (RAG) dengan integrasi JWT yang dirancang spesifik dengan fokus utama untuk penyediaan pengetahuan domain SPBE bagi pengguna internal BSSN dengan PUSDATIK sebagai pengelola aplikasi. Pada tahap ini, sistem difokuskan pada domain SPBE. Berbeda dengan penelitian-penelitian sebelumnya yang umumnya hanya berfokus pada optimasi pencarian AI (RAG) atau perlindungan model bahasa dari serangan *prompt injection* [16], keterbaruan pada penelitian ini terletak pada integrasi komprehensif antara sistem penalaran hukum dan pembatasan keamanan operasional yang ketat. Sistem ini secara spesifik mengatasi kompleksitas dokumen regulasi SPBE yang bersifat hierarkis dan saling merujuk. Lebih dari sekadar membangun *chatbot*, penelitian ini mengintegrasikan kecerdasan buatan dengan mekanisme validasi respons berbasis domain yang spesifik [1], serta keamanan arsitektur jaringan internal melalui implementasi JSON Web Token (JWT) yang terhubung dengan *Active Directory* menggunakan *Policy Based Access Control* (PBAC). Pengujian yang dilakukan tidak hanya memvalidasi akurasi jawaban menggunakan kerangka

RAGAS dan penerimaan pengguna melalui BUS-11, tetapi juga memvalidasi ketahanan autentikasi endpoint API *chatbot* terhadap kerentanan serangan akses ilegal dengan berpedoman pada standar OWASP API Security Top 10. Melalui pendekatan ini, produk yang dihasilkan diharapkan mampu memberikan kontribusi besar sesuai standar evaluasi dan menjadi solusi strategis dalam mempertahankan standar tinggi tata kelola BSSN serta menutup celah interpretasi hukum SPBE yang selama ini menjadi hambatan operasional.

I.2 RUMUSAN MASALAH

Berdasarkan latar belakang yang telah diuraikan, rumusan permasalahan dalam penelitian Tugas Akhir ini, yaitu:

- a. Bagaimana tingkat akurasi informasi dan pengetahuan domain SPBE yang dihasilkan oleh sistem asisten cerdas berbasis RAG jika diukur menggunakan metrik *Retrieval Augmented Generation Assessment* (RAGAS)?
- b. Sejauh mana tingkat penerimaan dan kepuasan pengguna internal BSSN terhadap sistem asisten cerdas berdasarkan pengukuran menggunakan metode *Chatbot Usability Scale* (BUS-11)?
- c. Bagaimana efektivitas penerapan mekanisme autentikasi berbasis JWT pada layanan *chatbot* dalam menanggulangi kerentanan berdasarkan standar OWASP API Security Top 10?

I.3 PEMBATAAN MASALAH

Dalam penelitian Tugas Akhir ini, terdapat beberapa pembatasan yang digunakan yaitu meliputi :

- a. *Front-end* dibangun menggunakan *Framework* Vue.js.
- b. *Back-end* dikembangkan menggunakan bahasa Python.
- c. *Vector database* yang digunakan pada *chatbot* adalah Qdrant.
- d. Model LLM yang digunakan adalah Qwen 2.5 7B-instruct
- e. Algoritma yang digunakan untuk JSON Web Token (JWT) adalah HS256 (HMAC-SHA256)
- f. *Framework* yang digunakan untuk menilai sistem RAG adalah RAGAS.
- g. *Framework* yang digunakan untuk menilai kepuasan pengguna adalah BUS-11
- h. *Framework* yang digunakan untuk pengujian kerentanan autentikasi *endpoint* mengacu pada standar OWASP API Security Top 10
- i. Mekanisme autentikasi yang digunakan adalah JSON Web Token (JWT) yang terhubung dengan *Active Directory* BSSN, dengan pembedaan hak akses berdasarkan peran pengguna (PBAC).
- j. Pengujian kegunaan aplikasi dilakukan oleh pengguna internal BSSN.
- k. Aplikasi dikembangkan untuk *deployment* di lingkup jaringan internal BSSN dan dikelola oleh PUSDATIK.
- l. *Chatbot* hanya menerima *input* berupa teks.

- m. *Knowledge base chatbot* dibatasi pada dokumen domain SPBE yang disediakan oleh PUSDATIK.

I.4 TUJUAN DAN MANFAAT

I.4.1 Manfaat

Tujuan dari penelitian tugas akhir ini adalah sebagai berikut:

- a. Untuk mengetahui tingkat akurasi informasi dan pengetahuan domain SPBE yang dihasilkan oleh sistem asisten cerdas berbasis RAG jika diukur menggunakan metrik *Retrieval Augmented Generation Assessment* (RAGAS).
- b. Untuk mengetahui Sejauh mana tingkat penerimaan dan kepuasan pengguna internal BSSN terhadap sistem asisten cerdas yang dikembangkan berdasarkan pengukuran menggunakan metode *Chatbot Usability Scale* (BUS-11).
- c. Untuk mengetahui efektivitas penerapan mekanisme autentikasi berbasis JWT pada layanan *chatbot* dalam menanggulangi kerentanan berdasarkan standar OWASP API Security Top 10.

I.4.2 Manfaat

Penelitian ini diharapkan dapat bermanfaat bagi seluruh pihak. Beberapa manfaat yang diharapkan di antaranya adalah:

- d. Memberikan pengetahuan bagi peneliti dan pembaca mengenai pemanfaatan teknologi *chatbot* berbasis RAG dalam menyediakan layanan informasi domain SPBE bagi pengguna internal BSSN.
- e. Menjadi referensi bagi PUSDATIK selaku pengelola sistem dalam mengembangkan solusi berbasis AI yang dapat mempercepat proses transfer pengetahuan dan meningkatkan konsistensi interpretasi regulasi SPBE di kalangan pengguna internal BSSN.
- f. Memberikan referensi bagi penelitian selanjutnya terkait pengembangan aplikasi *chatbot* dengan integrasi RAG.

I.5 SISTEMATIKA PENULISAN

Penulisan Proposal ini terbagi menjadi tiga bab yang saling berkaitan membentuk satu kesatuan dengan sistematika penulisan sebagai berikut:

BAB I : PENDAHULUAN

Bab ini membahas mengenai latar belakang masalah, rumusan masalah, pembatasan masalah, tujuan dan manfaat, serta sistematika penulisan.

BAB II : TELAAH KEPUSTAKAAN

Bab ini membahas konsep-konsep dan teori-teori yang berkaitan dan mendukung penelitian

BAB III : METODOLOGI PENELITIAN

Bab ini membahas mengenai metodologi penelitian yang dilakukan selama penelitian.

BAB II

TELAAH KEPUSTAKAAN

II.1 LANDASAN TEORI

II.1.1 Sistem Pemerintah Berbasis Elektronik (SPBE)

Transformasi digital dalam tata kelola pemerintahan Indonesia mengalami perubahan signifikan melalui implementasi Sistem Pemerintahan Berbasis Elektronik (SPBE). SPBE merepresentasikan paradigma baru pengelolaan administrasi negara yang mengintegrasikan teknologi informasi dan komunikasi guna meningkatkan efisiensi, transparansi, serta kualitas pelayanan publik. Kerangka regulasi utama SPBE diatur dalam Peraturan Presiden Nomor 95 Tahun 2018, yang kemudian diturunkan ke dalam berbagai regulasi teknis, termasuk Peraturan Menteri PANRB Nomor 59 Tahun 2020 tentang Pedoman Teknis Penerapan SPBE [17].

Selain aspek regulasi, penerapan SPBE secara operasional harus berlandaskan pada tujuh prinsip utama sebagaimana diamanatkan peraturan perundang-undangan, yaitu efektivitas, keterpaduan, kesinambungan, efisiensi, akuntabilitas, interoperabilitas, dan keamanan [18]. Prinsip keterpaduan dan interoperabilitas menjadi sangat krusial karena bertujuan untuk menghapus stigma birokrasi yang selama ini cenderung berjalan secara terpisah-pisah antar instansi. Lebih lanjut, penerapan prinsip interoperabilitas memungkinkan pertukaran data antar sistem elektronik dapat dilakukan secara *real-time* tanpa batasan ruang dan waktu, yang merupakan prasyarat mutlak bagi efisiensi layanan publik modern. Hal ini sejalan dengan tujuan akhir SPBE untuk mewujudkan *Good Governance* yang dicirikan oleh supremasi hukum, transparansi, partisipasi masyarakat, dan akuntabilitas [18].

Dalam konteks pelayanan, ekosistem SPBE tidak hanya terbatas pada efisiensi internal, tetapi mencakup interaksi yang luas meliputi *Government to Citizen* (G2C) untuk mempermudah akses masyarakat terhadap informasi, *Government to Business* (G2B) untuk mendukung dunia usaha, *Government to Government* (G2G) untuk kolaborasi antar pemerintah, serta *Government to Employees* (G2E) untuk manajemen kepegawaian [19]. Implementasi layanan berbasis elektronik ini secara signifikan menghilangkan hambatan fisik dan geografis, memungkinkan masyarakat mengakses layanan publik dari mana saja tanpa harus mengunjungi kantor pemerintahan secara langsung. Transformasi ini mengubah paradigma pelayanan dari yang sebelumnya berbelit-belit dan lambat menjadi pelayanan yang transparan, cepat, dan akuntabel [18].

BSSN, melalui Pusat Data dan Teknologi Informasi Komunikasi (PUSDATIK), memegang peran strategis sebagai pengelola infrastruktur data yang mendukung

keamanan siber nasional. Kompleksitas regulasi SPBE menuntut mekanisme akses informasi yang tidak hanya efisien tetapi juga aman. Tantangan krusial yang dihadapi saat ini adalah penyediaan akses cepat terhadap informasi regulasi yang dinamis, tanpa mengorbankan kerahasiaan data sensitif, seperti arsitektur sistem dan manajemen kerentanan yang jika terekspos dapat mengancam infrastruktur kritis pemerintah.

Mengingat lingkup kerja PUSDATIK yang mencakup pengelolaan keamanan informasi dan penjaminan kelangsungan data BSSN, diperlukan sebuah sistem cerdas yang dapat membantu pengguna internal BSSN, terutama pegawai baru, untuk memahami dan menginterpretasikan regulasi SPBE secara cepat dan konsisten. Hal ini mendorong PUSDATIK untuk mengambil peran sebagai pengembang solusi AI berbasis RAG yang dapat dimanfaatkan oleh pegawai internal BSSN pada domain SPBE.

II.1.2 Asisten Cerdas Berbasis LLM (Large Language Models)

Asisten cerdas merupakan sistem perangkat lunak yang memanfaatkan teknologi kecerdasan buatan untuk memahami, memproses, dan merespons permintaan *user* secara natural dan mengetahui konteks yang dimaksud [1]. Dalam konteks organisasi, asisten cerdas berfungsi sebagai antarmuka interaktif yang memfasilitasi akses informasi, otomasi tugas, dan pengambilan keputusan berbasis data [2]. Perkembangan pesat dalam bidang *Natural Language Processing* telah memungkinkan asisten cerdas untuk memahami pertanyaan kompleks dan memberikan jawaban yang relevan dengan konteks percakapan [3].

Perbedaan mendasar mengenai sistem tanya jawab konvensional dengan asisten cerdas adalah pada bagian pemrosesan *input* informasi yang tidak dimiliki oleh sistem konvensional, asisten cerdas modern menggunakan *Large Language Models* (LLM) yang mampu memahami semantik dan konteks percakapan secara mendalam [7]. Kemampuan ini memungkinkan asisten cerdas untuk menangani pertanyaan yang bersifat ambigu dan melakukan *reasoning* bagi tiap pertanyaan yang memerlukan penalaran logis [4].

LLM adalah model *neural network* yang dilatih menggunakan miliaran parameter dan data teks *multi domain* untuk memprediksi kata berikutnya dalam suatu urutan (*auto-regressive modeling*). LLM mampu untuk memanfaatkan data teks *multi domain* dalam jumlah besar yang berasal dari berbagai repositori, seperti *Common Crawl*, *Project Gutenberg* (buku), artikel ilmiah, hingga kode pemrograman yang dilatih menggunakan *self supervised*, di mana model belajar memahami struktur bahasa dengan dua tahap utama, yaitu *Pre training* dan *Fine tuning* yang memungkinkan penerapan lintas tugas tanpa modifikasi parameter yang berat dengan menggunakan dua paradigma utama, yaitu

- a. *Zero-shot Learning* merupakan kemampuan model untuk menyelesaikan tugas baru hanya dengan instruksi deskriptif tanpa diberikan contoh sebelumnya misalnya, menerjemahkan teks atau menganalisis sentimen hanya dengan *prompt* saja.
- b. *Few-shot Learning* merupakan kemampuan model untuk beradaptasi dengan tugas tertentu hanya dengan diberikan beberapa contoh demonstrasi dalam konteks (*in-context learning*). Hal ini menegaskan posisi LLM sebagai meta learners yang fleksibel, berbeda dengan model generasi sebelumnya yang kaku [11].

LLM digunakan sebagai inti pemrosesan bahasa alami dalam asisten cerdas karena kemampuannya memahami konteks, mengikuti instruksi, dan menghasilkan respons yang sesuai dan bisa dipercaya. Dalam penelitian ini, penggunaan LLM diintegrasikan ke dalam sistem asisten cerdas untuk mendukung interaksi pengguna secara natural.

II.1.3 Retrieval Augmented Generation (RAG)

Retrieval-Augmented *Generation* merupakan salah satu arsitektur *Artificial Intelligence* yang menggabungkan kemampuan pencarian informasi dengan generasi teks menggunakan LLM. Pendekatan ini pertama kali diperkenalkan untuk mengatasi keterbatasan model dalam memahami pertanyaan *user* karena terlalu terpaku pada parameter model yang sudah dilatih sebelumnya [20]. Dalam implementasinya, RAG bekerja dengan mengambil dokumen yang relevan dari pertanyaan *user* melalui basis pengetahuan eksternal, kemudian menggunakan informasi tersebut sebagai konteks tambahan untuk menghasilkan respons yang lebih akurat.


Arsitektur RAG terdiri dari tiga komponen utama, yaitu *retriever* yang bertugas mencari dokumen relevan, *knowledge base* yang menyimpan informasi dalam bentuk vektor *embedding*, dan generator yang menghasilkan respons berdasarkan dokumen yang ditemukan [21]. Keunggulan pendekatan ini terletak pada kemampuannya untuk mengakses informasi spesifik domain tanpa perlu melatih ulang model bahasa besar, sehingga lebih efisien dari segi komputasi dan memungkinkan pembaruan pengetahuan secara dinamis.

Sebagian besar komponen dalam arsitektur RAG mencakup: *Document Encoder* yang merubah teks menjadi vektor representasi (menggunakan model seperti BERT atau DPR); Query Encoder untuk merubah kueri pengguna menjadi sebuah kode tertentu; *Retriever* yang melakukan pencarian kemiripan vektor pada *database*; dan Generator yang memproduksi teks jawaban[22]. Didapatkan pula bahwa performa *retriever* adalah faktor kritis di mana memiliki peningkatan sebanyak 10% pada *recall@k* dan dapat meningkatkan akurasi jawaban hingga 20% [23]. Lebih lanjut,

metode *dense retrieval* terbukti mengungguli metode tradisional, seperti BM25 dengan margin signifikan dalam berbagai tolak ukur [24] .

II.1.3.1 Taksonomi dan Variasi Arsitektur RAG

Evolusi RAG telah melahirkan berbagai varian arsitektur. Penelitian oleh Gao pada 2024 mengklasifikasikan RAG ke dalam tiga kategori utama: *Naive*, *Advanced*, dan *Modular* [8].



Gambar 2. 1 Jenis pendekatan RAG [8]

1. Naive RAG merupakan pendekatan paling sederhana dalam RAG karena hanya memproses *query* dari penggunaan yang langsung digunakan untuk melakukan retrieval. Dokumen yang ada kemudian digabungkan dengan *prompt user* dan diberikan ke model LLM. Kelebihan pendekatan ini mudah diimplementasikan dan cocok untuk kasus sederhana, tetapi tahapan yang singkat membuat pendekatan ini tidak memiliki optimasi pada tahap *retrieval* maupun *reasoning* yang berakibat hasil jawaban kurang relevan jika dokumen yang diambil kurang tepat.
2. Advanced RAG berusaha mengimplementasikan optimasi pada sebelum pengambilan data, seperti *query expansion* dan *hypothetical document embeddings* serta setelah pengambilan data, yaitu *reranking*. Teknik *hypothetical embeddings* dapat meningkatkan akurasi hingga 18% [25]. Pendekatan ini lebih baik dibanding *naive* RAG karena menghasilkan jawaban lebih akurat dan relevan, namun membutuhkan sumber daya

komputasi yang lebih besar dan sulit diimplementasikan dibanding naïve RAG [8].

3. Modular RAG mengedepankan fleksibilitas berupa orkestrasi modul secara fungsional, yakni memungkinkan integrasi komponen seperti pengambilan iteratif dan reflektif. Pendekatan modular ini bekerja dengan membagi sistem ke dalam modul terpisah, seperti *retrieval*, *reranking*, *reasoning*, dan *post-processing* yang terbukti meningkatkan kinerja spesifik tugas hingga 30% karena memiliki skalabilitas tinggi serta mudah dikustomisasi sesuai kebutuhan jika dibandingkan arsitektur monolitik, namun agar bisa bekerja secara maksimal diperlukan desain arsitektur yang matang [26].

II.1.3.2 Optimasi Sistem dan *Vector database*

RAG bergantung pada sistem yang ada, sistem ini bukan hanya pada bagian awal saja, namun ada banyak komponen yang mempengaruhi kualitas hasilnya, berupa strategi *Chunking* yang menjadi aspek fundamental. *Chunking* ini bekerja dengan memotong bagian dokumen yang panjang menjadi lebih kecil agar lebih mudah di *retrive*, untuk jumlah *chunk* yang optimal pada dokumen teknis sejumlah 200-400, jumlah potongan yang kecil membuat konteks antar kalimat menjadi tidak berhubungan sementara itu jika potongan terlalu besar dapat memperlambat proses pencarian. Selain itu, strategi *overlap* berupa tumpang tindih antar *chunk* efektif meminimalkan kehilangan konteks [27].

Vector database merupakan komponen kunci dalam sistem RAG yang berfungsi untuk menyimpan dan melakukan pencarian terhadap *embedding* dari dokumen eksternal. *Embedding* ini merepresentasikan informasi semantik dari data dan memungkinkan proses pencarian berbasis kemiripan, sehingga model LLM dapat memperoleh konteks yang relevan sebelum menghasilkan respons ke pengguna [28]. Pemilihan model *embedding* dan optimasi indeks vektor sangat krusial karena mempengaruhi komputasi yang dilakukan oleh komputer. Contoh algoritma yang diterapkan pada *vector database*, seperti *Hierarchical Navigable Small World* (HNSW) untuk menjawab kebutuhan akan latensi ultra rendah dengan efisien tanpa kompresi berat, kemudian juga ada *Inverted File Index* (IVF) yang menjawab kebutuhan efisiensi penyimpanan jika memiliki memori komputer terbatas, keduanya telah menjadi standar industri untuk pencarian skala besar dengan latensi rendah pada zaman sekarang [29] [30]. *Library* populer yang menerapkan kedua algoritma tersebut adalah FAISS (*Facebook AI Similarity Search*), Milvus, dan Weaviate [29][30].

Selain itu optimasi sistem tidak hanya bergantung pada penggunaan model LLM dan *vector database*, pendekatan *hybrid search* yang menggabungkan pencarian semantik dan leksikal menggunakan BM25 terbukti memberikan hasil superior, terutama untuk pernyataan dengan istilah spesifik terhadap kata atau kalimat [31].


Penggunaan BM25 dengan frekuensi retrieval tinggi dan mekanisme reranking terdedikasi direkomendasikan sebagai strategi yang efektif dan efisien untuk meningkatkan kinerja model LLM tanpa perlu memodifikasi parameter model tersebut [32].

II.1.4 JSON Web Token (JWT)

JSON Web Token (JWT) adalah mekanisme autentikasi berbasis token yang digunakan secara luas pada arsitektur RESTful API untuk menyediakan verifikasi identitas yang *stateless* dan skalabel [33]. JWT merupakan pendekatan untuk mengirimkan identitas dari *server* dan klien dalam bentuk objek JSON yang ditandatangani secara kriptografis. Token ini terdiri dari tiga bagian yang dipisahkan oleh tanda titik, yaitu *Header* yang berisi informasi algoritma enkripsi yang digunakan, *Payload* yang berisi data pengguna, dan *Signature* yang digunakan untuk memverifikasi keaslian token. Karakteristik *stateless* JWT menjadikannya pilihan yang ideal untuk autentikasi pada arsitektur RESTful API karena *server* tidak perlu menyimpan *session*, sehingga skalabilitas sistem dapat terjaga dengan baik [33]. *Signature* ini berfungsi untuk menjamin integritas dan autentisitas token. Dalam skema simetris HMAC, proses hashing dilakukan menggunakan secret key bersama, sedangkan dalam skema asimetris seperti RSA atau ECDSA, signature dihasilkan menggunakan private key dan diverifikasi menggunakan public key [34].

JWT mendukung berbagai algoritma *signing*, seperti HS256, HS384, HS512 dengan basis HMAC, kemudian ada juga yang berbasis RSA, dan ECDSA [34]. Berdasarkan penelitian yang ada terhadap kinerja algoritma simetris (HS256) dan asimetris (RS256), algoritma HS256 terbukti memberikan efisiensi yang lebih baik untuk arsitektur API. Secara empiris, HS256 mampu membangkitkan token lebih cepat dan lebih ringan dibandingkan RS256. Mengingat *chatbot* RAG akan dijalankan pada lingkungan internal PUSDATIK, implementasi HS256 dinilai paling optimal karena meminimalkan overhead sistem [35].

Terdapat alur kerja dari JWT token dijelaskan dari gambar 2.2 yang dapat dipahami melalui pendekatan *lifecycle* dan dapat diidentifikasi kerentanan secara sistematis



Gambar 2. 2 Skema *lifecycle* dari JWT [36]

Stage 0 dimulai dengan inisiasi akses berupa pengguna mengirimkan kredensial kepada layanan autentikasi yang disimbolkan **SAAuth**. Pada *Stage 1*, jika proses autentikasi berhasil, **SAAuth** akan menghasilkan token dengan menyusun *payload claims* serta menandatangani token tersebut sebelum dikirimkan ke klien. Selanjutnya, pada *stage 2*, klien akan menyimpan token yang diterima dalam bentuk *cookies* atau *local storage* di *browser*. Kemudian dilanjutkan dengan *stage 3* berupa saat token dikirim Kembali ke *server* melalui *header HTTP Authorization* dengan skema *bearer* pada awal token setiap kali ingin mengakses *URL* yang diinginkan. Terakhir, pada *stage 4*, yaitu *server* melakukan verifikasi *signature* dan validasi otoritas yang diberikan sesuai dengan *payload* yang ada [36].

Penelitian tentang implementasi JWT pada keamanan API menunjukkan bahwa JWT dengan algoritma HMAC memberikan keamanan yang memadai untuk sistem manajemen sesi sekaligus mempertahankan performa yang baik [37]. Salah satu aspek penting dalam implementasi JWT adalah pengelolaan masa berlaku token (*token expiry*). Klaim *expired* dalam *payload* JWT mendefinisikan waktu kedaluwarsa token, yaitu jika token digunakan setelah waktu tersebut, *server* wajib menolak permintaan tersebut dan mengembalikan respons *'401 Unauthorized'*. Mekanisme ini penting untuk mencegah penyalahgunaan token yang telah bocor atau digunakan secara tidak sah [37]. Skenario token *expired* menjadi salah satu pengujian wajib dalam validasi keamanan sistem *chatbot* untuk memastikan sistem berperilaku sesuai standar keamanan yang berlaku.

II.1.5 Pengukuran *Chatbot*

Evaluasi terhadap sistem *chatbot* dalam konteks layanan internal pemerintahan tidak hanya berhenti pada aspek fungsionalitas teknis, tetapi juga harus menyentuh dimensi kualitas informasi dan pengalaman pengguna. Hal ini sejalan dengan tujuan

penyelenggaraan Sistem Pemerintahan Berbasis Elektronik (SPBE) yang ditujukan untuk mewujudkan proses kerja yang efisien, efektif, serta meningkatkan kualitas layanan. Untuk memastikan sistem yang dibangun memenuhi standar tersebut, penelitian ini menggunakan dua instrumen evaluasi utama, *Retrieval Augmented Generation Assessment* (RAGAS) untuk kualitas jawaban dan *Chatbot Usability Scale* (BUS-11) untuk mengukur penilaian antarmuka percakapan.

II.1.4.1 *Retrieval Augmented Generation Assessment (RAGAS)*

Tantangan utama dalam model generatif adalah memastikan bahwa informasi yang disampaikan kepada pengguna internal akurat dan tidak menyimpang dari regulasi. Dalam konteks layanan internal pemerintahan, akurasi informasi adalah mutlak karena pengguna berhak mendapatkan kepastian rujukan saat memahami kebijakan dan regulasi. RAGAS (*Retrieval Augmented Generation Assessment*) adalah kerangka kerja evaluasi otomatis yang dirancang khusus untuk mengukur kinerja arsitektur RAG tanpa memerlukan jawaban manusia yang ekstensif pada setiap pengujian [12]. Pada penelitian ini pengujian keefektifan performa *chatbot* akan diukur menggunakan sebuah *Framework RAGAs*. *Framework* ini mengevaluasi tiga komponen utama, yaitu *query*, *context*, dan *response*, dengan memecahnya menjadi empat komponen evaluasi, yaitu *context precision*, *context recall*, *answer relevancy*, dan *faithfulness*.

Metrik *context precision* atau sering disebut *context relevancy* berfungsi mengukur rasio sinyal terhadap *noise* dalam konteks yang diambil. Konteks yang berkualitas harus memuat informasi yang relevan sebanyak mungkin dengan meminimalkan gangguan informasi yang tidak perlu, sehingga proses penalaran model menjadi lebih efisien dan akurat. Metrik *context precision* berfungsi untuk mengukur sejauh mana sistem mampu memprioritaskan *chunk* yang relevan di urutan awal dalam daftar konteks yang diambil. Hal ini krusial karena *Large Language Model* (LLM) cenderung memberikan bobot perhatian yang lebih besar pada informasi yang muncul di awal konteks, sehingga dokumen yang tidak relevan di posisi atas dapat mendegradasi kualitas jawaban. Mekanisme penghitungannya menurut persamaan 2.1 variabel v_k bertindak sebagai filter biner yang hanya bernilai 1 jika dokumen pada urutan ke- k relevan, dan 0 jika tidak. Sistem kemudian menghitung presisi kumulatif pada setiap tingkat peringkat (k), namun hanya menjumlahkan skor tersebut jika dokumen pada posisi itu relevan. Hasil penjumlahan ini kemudian dibagi dengan total item relevan yang tersedia. Dengan mekanisme ini, rumus secara matematis akan menghasilkan skor rendah jika dokumen penting justru terkubur di urutan bawah, karena presisi kumulatif pada posisi tersebut akan memiliki nilai yang kecil.

$$CP = \frac{\sum_{k=1}^K (\text{Precision}@k \times v_k)}{\text{Total item relevan}} \quad (2.1)$$

Setelah itu ada *context recall* yang mengukur apakah semua informasi yang diperlukan untuk menjawab pertanyaan pengguna benar-benar berhasil diambil dari basis pengetahuan, skor *context recall* dihitung sebagai proporsi jumlah klaim dalam referensi yang berhasil ditemukan dalam konteks yang diambil, sesuai dengan rumus (2.2), nilai skor berkisar antara 0 dan 1, di mana nilai 1 mengindikasikan bahwa sistem *retriever* sempurna dalam mengambil seluruh informasi yang diperlukan tanpa ada fakta penting yang tertinggal. Sebaliknya, nilai yang rendah menunjukkan adanya *false negatives*, di mana sistem gagal menemukan dokumen yang memuat informasi penting berdasarkan *input* pengguna yang menyebabkan dokumen yang diambil kurang lengkap. Skor akhir diperoleh dengan membagi jumlah klaim yang berhasil ditemukan dengan total klaim yang seharusnya ada, sehingga nilai yang diambil mencerminkan kelengkapan informasi yang bisa diperoleh sistem.

$$CR = \frac{\text{Jumlah klaim dalam referensi yang didukung konteks}}{\text{Total jumlah klaim dalam referensi}} \quad (2.2)$$

Kemudian ada *faithfulness* yang mengukur konsistensi faktual jawaban yang dihasilkan. Tujuannya adalah memastikan bahwa setiap klaim dalam jawaban dapat disimpulkan secara logis dari konteks, yang sangat krusial dalam domain peraturan SPBE dan regulasi di mana akurasi informasi adalah mutlak. Sesuai dengan persamaan 2.3, skor *Faithfulness* (F) dihitung dengan membagi jumlah pernyataan yang terverifikasi didukung oleh konteks (|V|) dengan total pernyataan yang diekstrak (|S|). Skor akhir merupakan hasil pembagian antara pernyataan yang valid dengan total pernyataan yang dibuat, yang menunjukkan tingkat kemurnian fakta dalam jawaban sistem.

$$F = \frac{|V|}{|S|} \quad (2.3)$$

Terakhir ada *Answer Relevance* yang dituliskan dalam persamaan 2.4 untuk menilai apakah jawaban secara langsung menangani pertanyaan pengguna (q) tanpa bertele-tele. Relevansi diukur dengan beberapa pertanyaan hipotetis berdasarkan jawaban yang diberikan oleh *chatbot*, yang kemudian juga diubah menjadi vektor (q_i), kemudian menghitung kemiripan kosinus (*cosine similarity*) antara *embedding* pertanyaan asli dengan pertanyaan buatan tersebut. Skor *Answer Relevance* (AR) dirumuskan sebagai rata-rata kemiripan, nilai yang tinggi menunjukkan bahwa jawaban sistem sangat fokus dan relevan sehingga pertanyaan aslinya dapat diprediksi kembali dengan akurat.

$$AR = \frac{1}{n} \sum_{i=1}^n \text{cosine similarity}(q, q_i) \quad (2.4)$$

Hasil akhir penilaian dari kerangka kerja RAGAS direpresentasikan dalam bentuk *Ragas Score* seperti yang ditunjukkan pada persamaan 2.5. Ini merupakan nilai untuk memberikan gambaran performa sistem secara menyeluruh. Skor akhir menggunakan rata-rata harmonik dari keempat metrik komponen utama yang telah dihitung sebelumnya (yaitu *Faithfulness*, *Answer Relevance*, *Context Precision*, dan *Context Recall*). Untuk mendapatkan satu nilai final yang merepresentasikan kualitas sistem RAG secara holistik, skor metrik tersebut digabungkan menggunakan rumus rata-rata harmonik. Penggunaan rata-rata harmonik dipilih karena jika satu komponen saja memiliki nilai yang sangat buruk (misalnya *Faithfulness* 0.1), maka skor akhir RAGAS akan tertarik turun secara signifikan, meskipun metrik lainnya bernilai sempurna.

$$Ragas\ Score = \frac{4}{\frac{1}{F} + \frac{1}{AR} + \frac{1}{CP} + \frac{1}{CR}} \quad (2.5)$$

II.1.4.2 *chatbot Usability Scale (BUS-11)*

Evolusi antarmuka digital dari sistem point-and-click tradisional menuju agen percakapan cerdas (*chatbot*) telah menciptakan tantangan baru dalam evaluasi *User Experience* (UX). Skala kegunaan konvensional *System Usability Scale* (SUS), meskipun andal untuk antarmuka grafis dinilai kurang memadai untuk menangkap nuansa interaksi percakapan dari *chatbot* [14]. Untuk mengatasi kesenjangan ini, *Chatbot Usability Scale* (BUS) dikembangkan melalui proses yang ketat yang mereduksi instrumen awal sebanyak 15 poin menjadi versi 11 pertanyaan yang dikenal sebagai BUS-11 [38]. BUS-11 dirancang untuk mengukur kepuasan pengguna melalui lima dimensi atau faktor utama. Struktur ini telah dikonfirmasi stabil baik dalam pengembangan awal maupun dalam studi validasi lanjutan. Kelima faktor tersebut merepresentasikan aspek krusial dari interaksi manusia dengan *chatbot*, mulai dari kemudahan akses hingga keamanan privasi [15].

Tabel 2. 1 Struktur Faktor dan Poin BUS-11 [14]

Nomor	Faktor	Deskripsi	Fokus Evaluasi
1.	Aksesibilitas	Persepsi kemudahan akses terhadap fungsi <i>chatbot</i> .	Seberapa mudah pengguna menemukan dan mendeteksi fungsi <i>chatbot</i> .
2.	Fungsionalitas	Persepsi kualitas fungsi <i>chatbot</i> .	Kejelasan komunikasi, kemampuan menjaga konteks,

			dan kemudahan memahami respons.
3.	Percakapan	Persepsi kualitas percakapan dan informasi.	Kemampuan <i>chatbot</i> memahami tujuan pengguna dan memberikan informasi yang akurat serta relevan.
4.	Privasi	Persepsi privasi dan keamanan.	Keyakinan pengguna bahwa <i>chatbot</i> menginformasikan isu privasi dan keamanan data.
5.	Responsivitas	Waktu respons.	Persepsi pengguna terhadap kecepatan waktu tunggu balasan dari <i>chatbot</i> .

BUS-11 menunjukkan bahwa lima faktor di atas tetap valid dalam konteks budaya dan negara yang berbeda. Statistik menunjukkan validitas konvergen yang kuat, di mana skor BUS-11 memiliki korelasi positif yang signifikan dengan skala UMUX-LITE ($R=0.69, p<.001$), membuktikan bahwa BUS-11 mampu mengukur konstruksi kepuasan pengguna selaras dengan metrik standar industri lainnya namun dengan cakupan aspek percakapan yang lebih spesifik [15]. Cara perhitungan skor Bus-11 adalah dengan menghitung rata-rata dari kelima skor faktor pada tabel 2.1 kemudian dihitung menggunakan rumus 2.6, hasil dari perhitungan tersebut kemudian dikonversi ke tabel 2.2 sebagai acuan berapa persentase kelayakan *chatbot* berdasarkan pengalaman pengguna.

$$\text{Skor Akhir BUS} = \left(\frac{\text{rata - rata seluruh nilai faktor}}{5} \right) \times 100\% \quad (2.6)$$

Tabel 2. 2 Skor Bus-11 [14]

Label	Rentang Skor Keseluruhan (%)	Deskripsi Kinerja
<i>Very Poor</i>	0 s.d. <67%	Kualitas interaksi sangat rendah, memerlukan perbaikan mendasar.
<i>Poor</i>	≥ 67 s.d. <71%	Kualitas di bawah standar rata-rata.
<i>Average</i>	≥ 71 s.d. <74%	Kualitas interaksi standar, dapat diterima namun tidak istimewa.
<i>Good</i>	≥ 74 s.d. <80.1%	Kualitas interaksi memuaskan.
<i>Very Good</i>	$\geq 80.1\%$	Pengalaman pengguna sangat baik dan sangat memuaskan.

II.4.3 Evaluasi *JSON Web Token (JWT)*

Untuk memastikan implementasi mekanisme autentikasi JWT pada layanan *chatbot* tidak hanya aman tetapi juga efisien, diperlukan evaluasi yang terukur. Evaluasi ini mencakup dua aspek utama:

Pertama, pengujian keamanan API yang mengacu pada standar kerangka kerja keamanan siber (seperti OWASP API Security) [39]. Pengujian ini berfokus pada ketahanan *endpoint* API terhadap kerentanan autentikasi melalui menggunakan *software* pengujian API. Metrik yang diukur meliputi keberhasilan *server* dalam menolak manipulasi algoritma token (seperti eksploitasi *header* alg: none), serta ketepatan sistem dalam menangani *lifecycle* token melalui pengujian token *expiry* dan *session invalidation* [40].

Kedua, evaluasi terhadap implementasi *rate limiting* dan *session management* melalui simulasi peningkatan *request flood* untuk mengukur kemampuan penanganan kueri per detik [34]. Pengujian ini dilakukan menggunakan *network load testing* untuk memastikan *endpoint* API *chatbot* kuat dalam menahan kueri berlebih yang berpotensi melumpuhkan layanan, serta memvalidasi efektivitas mekanisme pemblokiran otomatis jika terdeteksi adanya anomali perilaku atau percobaan akses yang tidak sah [33].

II.2 PENELITIAN TERKAIT

Terdapat beberapa penelitian sebelumnya yang membahas topik terkait *chatbot*, LLM, RAG, dan domain hukum. Tabel 2.3 menyajikan hasil pembahasan dari *literature review* yang telah dilakukan. Pembahasan ini mencakup berbagai temuan penting dari penelitian-penelitian terkait yang relevan dengan penelitian Tugas Akhir ini.

II.2.1 Implementasi Retrieval-Augmented Generation dan Guardrails dalam Chatbot Berbasis Open-Source Large Language Model untuk Layanan Informasi LSPro [16]

Achmad Luthfan Aufar Hindami (2025) dalam penelitiannya yang berjudul "*Implementasi Retrieval-Augmented Generation dan Guardrails dalam Chatbot Berbasis Open-Source Large Language Model untuk Layanan Informasi LSPro*", mengembangkan sistem *chatbot* cerdas untuk Lembaga Sertifikasi Produk (LSPro) di lingkungan BSSN. Penelitian ini berfokus pada penggunaan model *open-source* (Llama 3.2 dan Qwen 2.5) yang dijalankan secara lokal untuk menjaga privasi data instansi, serta mengintegrasikan Guardrails AI untuk mencegah serangan *prompt injection* dan *jailbreaking*.

Penulis menemukan bahwa integrasi *hybrid retriever* (gabungan dense dan sparse retrieval) yang dilengkapi dengan reranker mampu menghasilkan skor akurasi tinggi, di mana komponen retrieval mencapai skor Context Precision 0,9667

dan Context Recall 0,9352 berdasarkan evaluasi RAGAS. Selain itu, penerapan guardrails terbukti menurunkan tingkat keberhasilan serangan (Attack Success Rate) dari 62,92% menjadi hanya 4,41%, yang menjamin keamanan interaksi di lingkungan pemerintah yang sensitif.

II.2.2 LRAGE: Legal Retrieval Augmented *Generation* Evaluation Tool [41]

Penelitian ini ditulis oleh Seungone Kim, Juyoung Suk, Ji Yong Cho, dan rekan-rekan peneliti lainnya pada tahun 2025 berfokus pada pengembangan alat evaluasi komprehensif bernama LRAGE untuk mengukur efektivitas sistem RAG pada domain hukum. Penelitian ini menguji berbagai komponen RAG, termasuk pemilihan korpus hukum, algoritma *retriever*, dan model reranker untuk melihat dampaknya terhadap akurasi jawaban.

Penulis menemukan fakta penting bahwa penerapan RAG tidak secara otomatis meningkatkan kinerja jika komponen *retriever* tidak dioptimalkan untuk konteks yang spesifik, di mana metode pencarian berbasis kata kunci, seperti BM25 dalam faktor tertentu masih mengungguli metode *dense retrieval* pada domain hukum tertentu yang belum disesuaikan. Lebih lanjut, studi ini menekankan bahwa evaluasi sistem hukum tidak bisa hanya mengandalkan metrik umum, melainkan memerlukan rubrik penilaian yang spesifik untuk mendeteksi domain hukum yang dimaksud.

Hasil eksperimen menunjukkan bahwa penggunaan korpus yang spesifik dan strategi *reranking* yang tepat sangat mempengaruhi skor akurasi pada perhitungan hukum dibandingkan hanya mengganti model LLM saja. Penelitian ini berkontribusi dengan menyediakan kerangka kerja evaluasi yang ketat untuk pengembangan sistem hukum berbasis AI dengan menegaskan bahwa validasi komponen *retrieval* adalah langkah fundamental sebelum menerapkan sistem yang lebih kompleks.

II.2.3 Performance and Security Comparison of Json Web Tokens (JWT) and Platform Agnostic Security Tokens (PASETO) on RESTful APIs

Penelitian ini ditulis oleh Adiva Fiqri Nugraha, Herman Kabetta, dan I Komang Setia Buana pada tahun 2023 berfokus pada perbandingan kinerja dan keamanan antara autentikasi berbasis JSON Web Token (JWT) dan Platform Agnostic Security Tokens (PASETO) pada RESTful API. Penelitian ini menguji dua aspek utama token autentikasi, yaitu pengujian kinerja yang diukur melalui waktu pembuatan token, ukuran token, dan waktu transfer token, serta pengujian keamanan yang dievaluasi menggunakan tiga kerentanan tertinggi berdasarkan standar OWASP API Security Top 10 (Broken Object Level Authorization, Broken

User Authentication, dan Excessive Data Exposure) beserta pengujian penetrasi CSRF,.

Penulis menemukan fakta penting bahwa JWT memiliki kinerja komputasi yang lebih cepat dan efisien dibandingkan PASETO. Hal ini dibuktikan dengan rata-rata waktu pembuatan token JWT yang hanya membutuhkan 0,5068 ms dibandingkan PASETO dengan waktu 2,4044 ms, serta waktu transfer data yang lebih singkat. Namun demikian, dari sisi keamanan, pengujian menunjukkan bahwa JWT memiliki kerentanan terhadap serangan *Broken User Authentication*, khususnya pada eksploitasi manipulasi *header* algoritma dan modifikasi *decode* pada bagian *payload* token. Lebih lanjut, studi ini juga menemukan bahwa jika token JWT disimpan dalam Cookie, ia rentan terhadap serangan CSRF.

Hasil eksperimen menunjukkan bahwa implementasi JWT pada arsitektur API menawarkan keunggulan kecepatan dan efisiensi yang krusial untuk aplikasi, namun membutuhkan validasi *backend* yang ketat terhadap struktur token berupa *header* dan *signature* untuk mencegah akses masuk ilegal. Penelitian ini berkontribusi dengan menyediakan pedoman skenario pengujian keamanan API yang komprehensif, yang diadopsi sebagai metode validasi ketahanan sistem *endpoint* pada arsitektur asisten cerdas.

Tabel 2. 3 Penelitian terkait


Peneliti dan Tahun Terbit	Judul Penelitian	Metode Penelitian	Hasil Penelitian	Keterkaitan	Gap Penelitian
Achmad Luthfan Aufar Hindami (2025)	<i>Implementasi Retrieval-Augmented Generation dan Guardrails dalam Chatbot Berbasis Open-Source Large Language Model untuk Layanan Informasi LSPPro</i>	Mengembangkan <i>chatbot</i> berbasis RAG dengan pengamanan Guardrails di <i>chatbot</i> pada layanan informasi di LSPPro yang dikembangkan guna memenuhi kebutuhan akan layanan publikasi informasi kepada publik dengan metode evaluasi RAGAS dan BUS-11	Penelitian ini memperoleh skor <i>chatbot</i> sebesar 0,9507 dalam aspek retrieval dan mendapatkan skor sebesar 0,9009 dalam aspek generation, kemudian mendapatkan total nilai sebesar 76,65% menggunakan BUS-11	Mengadopsi metode evaluasi menggunakan <i>Framework</i> RAGAS untuk menilai kualitas hasil RAG dan BUS-11 pada respon pengguna <i>chatbot</i>	Berfokus pada perlindungan model dari serangan <i>prompt injection</i> menggunakan Guardrails AI, namun tidak mencakup evaluasi keamanan pada lapisan autentikasi API. Penelitian ini melengkapi gap tersebut dengan menambahkan pengujian keamanan JWT berdasarkan standar OWASP API Security Top 10 serta mekanisme PBAC berbasis Active Directory.

Peneliti dan Tahun Terbit	Judul Penelitian	Metode Penelitian	Hasil Penelitian	Keterkaitan	Gap Penelitian
Seungone Kim, Juyoung Suk, Ji Yong Cho (2025)	<i>LRAGE: Legal Retrieval Augmented Generation Evaluation Tool</i>	Mengembangkan alat evaluasi komprehensif bernama LRAGE yang dirancang khusus untuk mengukur kinerja <i>retrieval</i> dalam sistem RAG hukum. Alat ini mengevaluasi dampak pemilihan korpus hukum, jenis <i>retriever</i> , <i>reranker</i> , dan LLM terhadap akurasi jawaban hukum,.	Menunjukkan bahwa <i>Agentic</i> RAG biasa tidak selalu meningkatkan kinerja dibanding metode RAG standar jika komponen <i>retriever</i> -nya tidak dioptimalkan untuk bahasa hukum. Penggunaan <i>reranker</i> dan korpus yang spesifik sangat mempengaruhi skor akurasi pada <i>benchmark</i> hukum.	Mengedepankan <i>output</i> yang muncul ke pengguna adalah hasil yang sudah dievaluasi <i>faithfulness</i> menggunakan pendekatan <i>Evaluator-Optimizer Workflow</i> , yaitu menyempurnakan <i>output</i> secara iteratif sebelum diberikan ke pengguna.	Mengembangkan alat evaluasi RAG untuk domain hukum secara umum dan tidak spesifik untuk bahasa Indonesia maupun konteks regulasi pemerintahan. Selain itu, LRAGE tidak mencakup evaluasi pengalaman pengguna. Penelitian ini memperluas dengan menambahkan evaluasi BUS-11 untuk mengukur kepuasan pengguna dan mengontekstualisasikan domain pada regulasi SPBE berbahasa Indonesia.
Adiva Fiqri Nugraha, Herman Kabetta, dan I Komang Setia Buana (2023)	<i>Performance and Security Comparison of Json Web Tokens (JWT) and Platform Agnostic Security Tokens (PASETO) on RESTful APIs</i>	Mengembangkan RESTful API dan menguji performa serta keamanan autentikasi JWT. Pengujian keamanan berfokus pada standar OWASP API Security Top 10 (seperti Broken Object Level	Hasil penelitian menunjukkan tingkat ketahanan JWT dalam implementasi API terhadap kerentanan struktur JWT (seperti manipulasi header alg: none dan	Mengadopsi metode evaluasi keamanan JWT pada endpoint API menggunakan standar OWASP API Security Top 10 dan pengujian kinerja komputasi token.	Membandingkan performa JWT dan PASETO pada RESTful API secara generik tanpa konteks spesifik sistem AI atau lingkungan pemerintahan. Penelitian ini mengimplementasikan JWT dalam konteks nyata sistem <i>chatbot</i> berbasis LLM di infrastruktur internal pemerintahan dengan

Peneliti dan Tahun Terbit	Judul Penelitian	Metode Penelitian	Hasil Penelitian	Keterkaitan	Gap Penelitian
		Authorization, Broken User Authentication) dan pengujian penetrasi CSRF.	modifikasi <i>payload</i>) beserta beban waktu komputasi saat pembentukan dan verifikasi token (<i>generation & verification time</i>).		integrasi Active Directory dan PBAC.

II.3 KERANGKA KONSEPTUAL

Gambar 2.2 merupakan kerangka konseptual yang menjadi acuan dalam melaksanakan penelitian ini. Kerangka konseptual terdiri dari latar belakang serta adanya permasalahan dan peluang yang diidentifikasi. Selanjutnya, penelitian ini mengusulkan pendekatan yang sesuai untuk menyelesaikan permasalahan yang ada. Dengan pendekatan tersebut, dilakukan implementasi strategi atau metode yang telah dirancang, sehingga memunculkan hasil yang dapat digunakan untuk menjawab pertanyaan penelitian.



Gambar 2. 3 Kerangka Konseptual

BAB III

METODOLOGI PENELITIAN

Bab ini membahas mengenai objek penelitian, jenis penelitian, desain penelitian, dan jadwal penelitian.

III.1 OBJEK PENELITIAN

Penelitian ini berfokus pada pengembangan *chatbot* domain SPBE berbasis Retrieval Augmented *Generation* (RAG) yang dikelola oleh PUSDATIK BSSN sebagai unit pengelola infrastruktur data dan teknologi informasi. Sistem ini dirancang sebagai alat bantu bagi seluruh pengguna internal BSSN dalam mengakses pengetahuan domain SPBE dengan fokus pada domain SPBE di tahap ini.


III.2 JENIS PENELITIAN

Jenis penelitian yang digunakan adalah pendekatan kuantitatif yang digunakan secara dominan pada tahap evaluasi sistem, di mana kinerja aplikasi diukur secara objektif menggunakan metrik numerik dari kerangka kerja *Retrieval Augmented Generation Assessment* (RAGAS) untuk menilai *faithfulness* dan relevansi jawaban. Selain itu penerimaan pengguna diukur menggunakan instrumen kuesioner terstandar *Chatbot Usability Scale* (BUS-11) yang menghasilkan data statistik deskriptif berupa skor persentase kepuasan pengguna dalam bentuk numerik.

III.3 DESAIN PENELITIAN

Penelitian ini menggunakan metode Design Science Research Methodology (DSRM) yang dikembangkan oleh Peffers et al. (2007). DSRM dipilih karena konsep penelitian ini berfokus pada penciptaan dan evaluasi artefak IT, yaitu aplikasi *chatbot* sebagai solusi untuk menyelesaikan masalah organisasi yang ada. Pendekatan ini sangat relevan untuk penelitian ini karena tujuan utamanya bukan hanya menguji teori, melainkan menghasilkan solusi praktis berupa perangkat lunak yang fungsional dan teruji [42].

Proses penelitian ini mengikuti enam tahapan iteratif DSRM, mulai dari identifikasi masalah hingga komunikasi hasil penelitian. Pemetaan aktivitas penelitian terhadap tahapan DSRM disajikan pada Gambar 3.1



Gambar 3. 1 *Design Science Research Methodology process model* [42]

III.3.1 *Problem Identification and Motivation*

Tahap ini bertujuan untuk mendefinisikan masalah penelitian secara spesifik dan membenarkan nilai dari solusi yang diusulkan. Berdasarkan wawancara yang dilakukan kepada salah satu pegawai PUSDATIK yang menjadi pionir pengembangan aplikasi tepatnya di unit kerja P22 Pengembangan Sistem dan Pengolahan Data yang berfokus pada pengembangan aplikasi pada lingkungan PUSDATIK dan BSSN, ditemukan bahwa PUSDATIK BSSN menghadapi tantangan dalam memastikan seluruh pengguna internal BSSN dapat menginterpretasikan regulasi SPBE yang kompleks dan saling merujuk secara konsisten. Proses manual saat ini dinilai tidak efisien dan rentan terhadap inkonsistensi. Selain itu, adanya perputaran personil dan kebutuhan pengguna internal yang beragam terhadap pengetahuan domain SPBE mengakibatkan hambatan dalam diseminasi pengetahuan. Hal ini berdampak pada pemahaman yang tidak merata terhadap domain SPBE di kalangan pengguna internal BSSN.

Motivasi penelitian ini adalah membuat sebuah alat bantu yang dapat mempercepat proses diseminasi pengetahuan domain SPBE agar dapat diakses secara mudah dan konsisten oleh seluruh pengguna internal BSSN tanpa bergantung sepenuhnya pada individu tertentu. Cara yang diajukan dalam penelitian ini untuk menutup celah inefisiensi tersebut adalah menggunakan teknologi *Retrieval Augmented Generation* (RAG) yang mampu memberikan panduan pengetahuan domain SPBE secara otomatis dan akurat. RAG dipilih karena bisa melatih agen yang tidak memiliki fokus pengetahuan sama sekali di bidang tertentu menjadi ahli walaupun dengan parameter yang kecil seperti 3 miliar parameter, ini mempermudah keandalan informasi yang dihasilkan karena LLM tidak menjawab berdasarkan pendapatnya sendiri dan berhalusinasi, tetapi menjawab berdasarkan fakta di dokumen yang ada.

III.3.2 Define the Objectives for a Solution

Berdasarkan permasalahan tersebut, tujuan utama penelitian ini adalah mengembangkan sebuah *Chatbot Expert System* berbasis *Artificial Intelligence* yang berfungsi sebagai asisten cerdas bagi seluruh pengguna internal BSSN dalam mengakses pengetahuan domain SPBE melalui DWS. Solusi ini ditargetkan tidak hanya sebagai alat bantu tanya jawab, tetapi harus memenuhi standar efisiensi operasional yang mampu mempercepat waktu pencarian informasi secara signifikan dibandingkan proses manual. Sistem juga dirancang untuk mencapai tingkat kehandalan yang tinggi dengan menyajikan informasi pengetahuan domain SPBE yang akurat dan minim kesalahan sehingga validitas informasi tetap terjaga bagi seluruh pengguna. Selain itu, solusi ini bertujuan untuk memastikan kegunaan dan keberterimaan pengguna melalui mekanisme interaksi yang intuitif melalui DWS, sehingga proses transfer pengetahuan dapat berjalan lancar

III.3.3 Design and Development

Pada tahap ini, peneliti merancang dan mengembangkan *artifact* sebagai solusi yang diusulkan berdasarkan tujuan yang telah ditentukan. Penelitian ini mengusulkan perancangan dan pengembangan *chatbot* berbasis LLM dengan pendekatan RAG. Pada Tabel 3.1 dijelaskan mengenai komponen RAG yang digunakan.

Tabel 3.1 Komponen RAG

No	Komponen	Fungsi
1	Model Qwen 3.5-4B	Model LLM yang digunakan untuk menjawab pertanyaan pengguna
2	Firqaaa/indo-sentence-bert-base	Model <i>embedding</i> untuk merubah hasil <i>chunk</i> menjadi vector
3	Qdrant	<i>Vector database</i>
4	BM25	Pencarian leksikal untuk mencari kata kunci dalam <i>vector database</i>
5	BAAI/bge-reranker-base	Model reranker untuk mengurutkan top-k <i>chunk</i>
6	Marker	Converter Pdf menjadi format Md

Pengembangan *chatbot* ini mencakup beberapa kegiatan, yaitu:

a. Pembentukan *Knowledge base*


Pada tahap ini diawali dengan wawancara kepada pihak PUSDATIK mengenai dokumen yang akan dijadikan *knowledge base chatbot*. Dokumen yang digunakan dapat berupa dokumen publik dan dokumen internal yang disetujui oleh PUSDATIK. Dokumen publik mencakup peraturan presiden, peraturan menteri, peraturan badan, dan pedoman teknis terkait SPBE. Dokumen internal

dapat mencakup kebijakan, SOP, FAQ, atau materi panduan domain SPBE yang relevan untuk kebutuhan pengguna internal BSSN. Seluruh dokumen diposisikan sebagai sumber pengetahuan *chatbot*, bukan sebagai bahan untuk menghitung nilai atau menyusun dokumen resmi SPBE.

Proses yang dilakukan adalah dengan mengunggah dokumen peraturan terlebih dahulu ke *User Interface* (UI) yang telah disediakan. Pada tahap ini, marker merupakan komponen yang dibutuhkan karena berfungsi untuk mengekstrak *file* pdf menjadi bentuk *markdown* dengan mempertahankan format aslinya dan membuang *noise* tidak penting, setelah itu dilanjutkan mengkonversi menjadi json untuk mempertahankan format dan lebih mudah dibaca oleh mesin. Dikarenakan beberapa dokumen yang digunakan sebagai *knowledge base* adalah dokumen peraturan SPBE yang memiliki struktur diawali dengan judul; dasar hukum; isi berupa bab, pasal, dan ayat; ketentuan umum; pegesahan; dan lampiran. Setelah struktur sudah dibagi sesuai kriteria, tahap selanjutnya adalah mengekstrak semua *chunk* tersebut menggunakan Firqaaa/indo-sentence-bert-base sebagai model *embedding* untuk mengubah potongan-potongan teks tersebut menjadi *vector*. Kemudian hasil *vector* yang sudah dihasilkan akan disimpan ke *vector database* qdrant yang kemudian akan menjadi dasar *chatbot* melakukan proses pemanggilan informasi.

b. Desain

Proses desain sistem dimulai dengan perancangan arsitektur *chatbot* yang berfokus pada perincian struktur sistem cerdas untuk layanan informasi SPBE. *Chatbot* ini dikembangkan menggunakan model LLM yang dikombinasikan dengan teknik *Retrieval-Augmented Generation* (RAG) untuk mengambil informasi yang presisi dari *knowledge base* yang telah dibentuk meliputi peraturan SPBE dan dokumen lainnya yang sudah diunggah sebelumnya.



Gambar 3.2 Konsep alur *chatbot*

Berdasarkan Gambar 3.2 interaksi sistem dimulai pada saat pengguna memasukkan *input*, setelahnya sistem menerima *input* pertanyaan pengguna dalam bentuk raw string melalui *endpoint* API. Untuk meningkatkan recall, diterapkan teknik *Query Rewriting* yang bertugas mentransformasi pertanyaan pengguna menjadi beberapa variasi semantik berupa memperluas kata atau kalimat yang kurang sesuai dengan domain SPBE menjadi lebih sesuai dengan tidak merubah maknanya. Langkah ini krusial untuk menjembatani celah antara bahasa kasual pengguna dengan bahasa formal regulasi.

Setelah itu masuk ke proses *Hybrid Retriever*. Sistem menggabungkan kekuatan pencarian semantik berupa *Vector Search* untuk tujuan memahami makna, konteks, dan niat pengguna dan pencarian leksikal berupa BM25 untuk mencari kata atau frasa yang persis sama antara kueri pengguna. Kedua hasil pencarian ini difusikan menggunakan metode *Reciprocal Rank Fusion* (RRF) untuk memilih *chunk* terbaik.

Selanjutnya, untuk meminimalisir *noise*, yaitu kesalahan dalam memahami dokumen yang sekilas mirip namun konteksnya salah, diterapkan tahap *Reranking* menggunakan model Cross-Encoder BAAI/bge-reranker-base, tugasnya adalah menilai ulang relevansi dokumen hasil fusi satu per satu terhadap pertanyaan

pengguna dengan tujuan memastikan bahwa hanya informasi yang benar-benar relevan yang diteruskan ke tahap generasi.

Dokumen yang lolos tahap *reranking* kemudian disusun menjadi paragraf konteks yang terstruktur. Konteks ini diintegrasikan ke dalam instruksi sistem melalui teknik *Prompt Engineering*. Struktur *prompt* dirancang secara ketat dengan menetapkan persona sistem sebagai ahli peraturan SPBE dan membatasi ruang lingkup jawaban hanya pada konteks yang disediakan sehingga tidak bias terhadap jawaban yang dihasilkan model LLM secara lokal menggunakan model yang tersedia di ollama. Pada saat penelitian ini dilakukan, Alibaba merilis Qwen 3.5 pada bulan Februari tahun 2026 yang menghadirkan sejumlah peningkatan signifikan dibandingkan pendahulunya, berupa arsitektur *hybrid Gated Delta Networks* dengan *sparse MoE* yang meningkatkan efisiensi *inference* dan *native Thinking Mode* untuk penalaran bertahap.

Sebelum respon disajikan kepada pengguna, sistem melakukan *Post-processing* yang berfungsi untuk memastikan bahwa klaim dalam jawaban didukung oleh teks dalam dokumen dan mengekstrak metadata dokumen (Nama Peraturan, Nomor Pasal, Halaman) untuk ditampilkan sebagai sitasi. Hal ini memberikan jaminan validitas informasi bagi pengguna internal BSSN dalam mengakses pengetahuan domain SPBE. *Post-processing* disini memiliki fitur lain, yaitu sebagai *respon validation* yang bertugas memverifikasi bahwa setiap klaim dalam respons yang dihasilkan dapat ditelusuri ke konteks dokumen yang tersedia. Jika respons mengandung klaim yang tidak didukung oleh dokumen sumber, sistem akan memberikan notifikasi atau meminta model LLM menghasilkan ulang jawabannya.

III.3.4 Demonstration

Setelah *chatbot* sudah selesai dikembangkan, tahap demonstrasi bertujuan untuk membuktikan bahwa artefak yang dikembangkan dapat berfungsi untuk memecahkan masalah pada satu atau lebih kasus. Aplikasi *chatbot* akan diimplementasikan dalam skenario simulasi di lingkungan PUSDATIK. Demonstrasi akan menampilkan bagaimana pengguna internal mengajukan pertanyaan tentang regulasi, istilah, kebijakan, atau prosedur domain SPBE dan bagaimana sistem menyajikan jawaban beserta referensi dokumen secara *real time*.

III.3.5 Evaluation

Tahap evaluasi mengukur seberapa baik artefak mendukung solusi masalah dibandingkan dengan tujuan yang ditetapkan. Evaluasi dilakukan menggunakan pendekatan kuantitatif dengan tiga instrumen utama yaitu Evaluasi Kinerja Sistem (RAGAS) untuk mengukur metrik *faithfulness*, *answer relevance*, *context precision*, dan *context recall* untuk memastikan jawaban *chatbot* tidak berhalusinasi dan sesuai dengan domain SPBE. Dataset evaluasi RAGAS disusun dari

skenario tanya jawab domain SPBE yang sering dibutuhkan pengguna internal yang terdiri dari 40 pasangan pertanyaan dan jawaban referensi yang divalidasi oleh personel PUSDATIK. Jika validator tidak setuju dengan daftar tersebut maka direvisi untuk mendapatkan pertanyaan dan jawaban paling relevan berdasarkan persetujuan validator.

Kedua adalah melakukan pengujian keamanan operasional *endpoint chatbot* yang meliputi simulasi penetrasi struktural dengan validasi masa berlaku token, serta simulasi serangan permintaan masif untuk memvalidasi keberhasilan mekanisme *rate limiting*. Pengujian ini bertujuan untuk memastikan sistem tetap aman dan responsif saat diterapkan di lingkungan internal PUSDATIK.

Ketiga adalah evaluasi pengguna menggunakan *Chatbot Usability Scale* (BUS-11) untuk mengukur tingkat kepuasan dan penerimaan pengguna akhir sistem. Kuesioner mencakup lima dimensi BUS-11, yaitu aksesibilitas, fungsionalitas, kualitas percakapan, privasi/keamanan, dan responsivitas. Responden evaluasi adalah pegawai BSSN yang secara operasional bertugas dalam proses evaluasi dan pengumpulan data dukung SPBE. Metode sampling yang digunakan adalah *purposive sampling*, yaitu pemilihan responden berdasarkan kriteria fungsional yang telah ditetapkan berupa pegawai BSSN yang secara aktif terlibat dalam proses evaluasi dan pengumpulan data dukung SPBE pada periode penilaian dan tidak terlibat dalam proses pengembangan sistem yang dievaluasi. Jumlah responden mengikuti ketersediaan calon pengguna internal dengan batas minimum 20 responden. Jika jumlah yang memenuhi kriteria kurang dari batas minimum, kondisi tersebut menjadi limitasi penelitian ini.

III.3.6 Communication

Pada tahap akhir, hasil penelitian ini dikomunikasikan melalui Laporan Tugas Akhir yang mendokumentasikan seluruh proses identifikasi masalah, desain arsitektur, pengembangan, hingga evaluasi sistem RAG dengan integrasi JWT sebagai lapisan keamanannya. Laporan ini secara khusus membahas efektivitas penggunaan sistem tersebut dalam melakukan navigasi dan ekstraksi pada dokumen hukum yang kompleks dengan tujuan membantu pegawai BSSN dalam mengakses dan memanfaatkan pengetahuan domain SPBE secara lebih efisien dan konsisten.

Selain itu, laporan ini memberikan kontribusi pengetahuan berupa analisis performa LLM yang dijalankan lokal untuk menjaga kedaulatan data. Arsitektur keamanan mencakup penggunaan JSON Web Token (JWT) yang terhubung dengan *Active Directory* untuk autentikasi pengguna. Hal ini dilakukan untuk memastikan bahwa layanan *chatbot* cerdas tidak hanya akurat dalam menyajikan informasi hukum, tetapi juga memiliki tata kelola akses yang selaras dengan infrastruktur keamanan di lingkungan BSSN.

BAB IV

HASIL PENELITIAN


Bab ini membahas hasil dari beberapa tahap desain penelitian yang telah dijelaskan pada subbab III.3. Beberapa tahap tersebut meliputi *design and development*, *demonstration*, dan *evaluation*.

IV.1 DESIGN AND DEVELOPMENT

Pada Subbab ini menjelaskan hasil desain dan pengembangan sistem dari sisi arsitektur, pembentukan *knowledge base*, autentikasi dan otorisasi, RAG engine, serta antarmuka pengguna. Setiap subbagian ditulis sebagai alur kerja, bukan sekadar daftar komponen, sehingga hubungan masukan, proses, keluaran, dan peran setiap komponen dalam sistem dapat terlihat.

IV.1.1 Arsitektur Sistem

Arsitektur sistem terdiri atas tiga lapisan utama. Lapisan pertama adalah *frontend* Vue.js yang menyediakan halaman *login*, *chat*, manajemen dokumen, detail dokumen, dan pratinjau sitasi. Lapisan kedua adalah *backend FastAPI* yang menyediakan endpoint autentikasi, endpoint dokumen, *endpoint chat streaming*, *endpoint* sesi, serta *endpoint* pendukung *retrieval*. Lapisan ketiga adalah penyimpanan dan model, yang mencakup SQLite, Qdrant, indeks BM25, model embedding, reranker opsional, dan LLM melalui Ollama.




Gambar 4.1 Arsitektur sistem

Alur utama sistem dimulai dari pengguna yang masuk melalui halaman *login*. Setelah autentikasi berhasil, pengguna dapat mengunggah dokumen PDF untuk membentuk *knowledge base* atau mengajukan pertanyaan pada halaman *chat*. Pada jalur dokumen, backend menyimpan metadata ke SQLite, mengekstrak teks, membentuk *chunk* terstruktur, mengunggah embedding ke Qdrant, lalu membangun

ulang indeks BM25. Pada jalur *chat*, backend memuat sesi, melakukan retrieval dari Qdrant dan BM25, menyusun konteks, mengirim *prompt* ke model bahasa, dan mengalirkan jawaban kembali ke frontend melalui Server Sent Events.

IV.1.2 Pembentukan *Knowledge base*

Pembentukan *Knowledge Base* disini berfungsi sebagai dasar ilmu pengetahuan dari *chatbot* yang akan disusun yang akan disimpan dan terdokumentasi di sistem. Tahap ini bertujuan untuk menjadikan data yang didapatkan dari PUSDATIK menjadi intisari pengetahuan yang dilatih guna mempermudah pengguna dalam mencari informasi yang akurat dan dapat dipercaya. Secara Garis besar proses pembentukan *knowledge base* diperlihatkan di gambar 4.1.



Gambar 4.2 Tahapan Pembentukan *Knowledge base*

IV.1.2.1 Pengumpulan Dokumen

Pembentukan dokumen menjadi tahap awal yang menentukan ketersediaan konteks bagi sistem RAG. Dokumen regulasi, pedoman, dan evaluasi SPBE tidak dipakai sebagai teks bebas, tetapi diproses menjadi potongan informasi dengan struktur, metadata, dan indeks pencarian. Tujuan proses ini adalah menyediakan sumber pengetahuan yang dapat ditelusuri kembali ketika pengguna mengajukan pertanyaan melalui antarmuka *chat*. Tabel berikut merinci daftar dokumen yang telah dikumpulkan dan diindeks ke dalam sistem. Tabel 4.1 menunjukkan daftar dokumen yang digunakan sebagai dasar pengetahuan yang didapatkan dari hasil wawancara sebelumnya ke pihak PUSDATIK

Tabel 4.1 Daftar hasil pengumpulan dokumen

Judul Dokumen	Deskripsi Singkat	Kategori	Ekstensi
---------------	-------------------	----------	----------

Perpres Nomor 95 Tahun 2018	Dasar hukum utama Sistem Pemerintahan Berbasis Elektronik.	Regulasi	.pdf
PP Nomor 71 Tahun 2019	Peraturan tentang Penyelenggaraan Sistem dan Transaksi Elektronik.	Regulasi	.pdf
Perpres Nomor 82 Tahun 2023	Percepatan Transformasi Digital dan Keterpaduan Layanan Digital Nasional.	Regulasi	.pdf
Perka BSSN Nomor 2 Tahun 2023	Tata Cara Pemantauan dan Evaluasi SPBE.	Regulasi	.pdf
Peraturan BSSN Nomor 8 Tahun 2024	Standar Keamanan Informasi dan Audit TIK.	Regulasi	.pdf
Pedoman Menpan RB Nomor 3 Tahun 2024	Panduan pelaksanaan evaluasi SPBE terbaru (2024).	Pedoman	.pdf
Laporan Evaluasi SPBE KemenpanRB 2023	Hasil penilaian tingkat kematangan SPBE tahun 2023.	Laporan	.pdf
Laporan Pelaksanaan Evaluasi SPBE 2024	Hasil penilaian dan temuan audit evaluasi SPBE 2024.	Laporan	.pdf

IV.1.2.2 *Document Ingestion Interface*

Proses masuknya utama tahap ini adalah berkas PDF yang diunggah melalui antarmuka manajemen dokumen. Pada sisi *frontend* menyediakan halaman untuk memilih berkas, menampilkan tahapan unggah, meminta pratinjau *chunk*, menyimpan hasil ke indeks, menampilkan daftar dokumen terindeks, menghapus dokumen, dan menjalankan sinkronisasi dari Qdrant. Fungsi pada *documentService.js* meneruskan operasi tersebut ke *endpoint backend* untuk *upload*, *preview*, *save*, *list*, *delete*, dan *sync*.

Gambar 4.3 menunjukkan bahwa frontend tidak melakukan ekstraksi atau *chunking* sendiri. Frontend hanya mengirim file dan meminta backend menjalankan tahapan pembentukan *knowledge base*. Pada komponen *DocumentsView.vue*, fungsi *upload* File, *previewChunks*, dan *saveDocument* mengatur status UI berdasarkan respons dari service tersebut. Pada sisi *backend*, *documents.py* mendefinisikan endpoint *upload*, *preview*, dan *save* daftar dokumen, detail dokumen, *chunk* dokumen, hapus dokumen, pembaruan *chunk*, penghapusan *chunk*, dan sinkronisasi dari Qdrant. Endpoint tersebut memanggil *DocumentManager* melalui dependency *get_manager*, sehingga API menjadi batas layanan dan logika siklus hidup dokumen berada pada *document_manager.py*.

```

export async function uploadDocument(file, onProgress) {
  const formData = new FormData()
  formData.append('file', file)
  const { data } = await api.post('/api/documents/upload', formData, {
    onUploadProgress: (e) => {
      if (typeof onProgress === 'function' && e.total > 0) {
        onProgress(Math.min(100, Math.round((e.loaded / e.total) * 100)))
      }
    }
  })
  return data
}

export async function previewDocument(docId) {
  const { data } = await api.post(`/api/documents/${docId}/preview`)
  return data
}

export async function saveDocument(docId) {
  const { data } = await api.post(`/api/documents/${docId}/save`)
  return data
}

```

Gambar 4.3 Fungsi *Upload*, *preview*, dan *save document*

Lebih jelasnya, pada Gambar 4.4 sistem melakukan pemanggilan *getDocument* untuk memuat informasi metadata utama dokumen dan *getDocumentChunks* untuk menarik seluruh daftar *chunk* yang terafiliasi dengan dokumen tersebut. Keunggulan utama dari arsitektur manajemen yang terpisah ini adalah diberikannya kendali penuh bagi pengguna untuk melakukan intervensi dan kurasi data. Apabila ditemukan ketidakakuratan hasil ekstraksi teks, misalnya kesalahan pembacaan OCR atau parsing tabel, pengguna dapat secara langsung menggunakan fungsi *updateChunk* untuk merevisi teks pada *chunk* yang spesifik. Selain itu, fungsi *deleteChunk* tersedia untuk membuang bagian teks yang dianggap sebagai noise (seperti nomor halaman atau header berulang) yang tidak memiliki nilai konteks. Melalui mekanisme ini, kurasi kualitas basis pengetahuan dapat dilakukan secara presisi dan efisien, tanpa mengharuskan pengguna untuk memperbaiki isi keseluruhan dokumen sumber lalu melakukan unggah ulang.

```

async function loadDocuments() {
  documents.value = await listDocuments()
}

async function syncFromQdrant() {
  const data = await syncDocuments()
  await loadDocuments()
}

async function deleteDocument() {
  await deleteDocumentById(deleteTarget.value.doc_id)
  deleteTarget.value = null
  loadDocuments()
}

```

Gambar 4.4 Fungsi daftar, sinkronisasi, dan hapus dokumen

IV.1.2.3 *Upload dan menyimpan metadata*

Selanjutnya, fungsi yang ditampilkan Gambar 4.5 memperlihatkan mekanisme pertahanan dan penyimpanan awal pada sisi backend. Selain melakukan validasi ukuran maksimum (*MAX_FILE_SIZE*) dan memastikan format berkas hanya PDF, fungsi ini bertanggung jawab penuh untuk mengidentifikasi (*doc_id*), mensterilkan nama berkas dari karakter yang tidak valid, menyimpan berkas fisik secara aman ke direktori lokal, dan menginisiasi rekaman metadata awal di basis data SQLite.

Tahap inisiasi ini memproses *doc_id* yang akan dikembalikan sebagai respons API ke frontend. Frontend kemudian menangkap dan menyimpan nilai tersebut ke dalam variabel *upload edDocId.value*. Tanpa adanya *feedback doc_id* ini, frontend tidak akan memiliki referensi yang sah untuk memicu tahapan sistem selanjutnya, yakni meminta proses ekstraksi teks dan menyimpan ke indeks.

```
def upload_file(self, file_content: bytes, original_filename: str) -> Dict[str, Any]:
    if len(file_content) > MAX_FILE_SIZE:
        raise ValueError(f"File too large. Maximum size is {MAX_FILE_SIZE // 1024 // 1024}MB")

    if not original_filename.lower().endswith(".pdf"):
        raise ValueError("Only PDF files are supported")

    doc_id = str(uuid.uuid4())[:8]
    safe_filename = re.sub(r"[^\w\.-]", "_", original_filename)
    stored_filename = f"{doc_id}_{safe_filename}"
    file_path = UPLOADS_DIR / stored_filename

    with open(file_path, "wb") as f:
        f.write(file_content)

    self.create_document(
        doc_id=doc_id,
        filename=stored_filename,
        original_filename=original_filename,
        file_size=len(file_content),
        file_path=str(file_path),
    )
```

Gambar 4.5 Fungsi *Upload* dan Menyimpan Metadata

IV.1.2.4 *Strategi Chunking*

Fungsi *chunk_document* bertindak sebagai pengatur untuk memecah teks dokumen. Berbeda dengan pendekatan RAG konvensional yang sering kali memotong teks berdasarkan batasan jumlah karakter atau kata yang berisiko memutus konteks kalimat, sistem ini mengadopsi pendekatan pemotongan berbasis struktur yang kuat. Penjelasan ini dipaparkan pada Gambar 4.6 berupa setelah tipe dokumen berhasil diidentifikasi pada tahapan sebelumnya, fungsi ini akan menerapkan strategi pemotongan yang dirancang khusus untuk masing-masing format:

1. Pada dokumen peraturan akan diarahkan ke fungsi *chunk_peraturan*. Fungsi ini memastikan bahwa teks tidak dipotong sembarangan, melainkan dipisah

dengan secara ketat mempertahankan hierarki hukumnya, seperti pemisahan berdasarkan Bab, Pasal, dan Ayat.

2. Untuk laporan dan pedoman SPBE akan diarahkan ke *chunk_laporan_spbe* atau *chunk_pedoman_spbe*, di mana pemotongan difokuskan pada pemisahan antar bab laporan, sub-bagian, matriks penilaian, atau indikator spesifik SPBE.
3. Terakhir, untuk dokumen Lainnya akan diproses melalui *chunk_laporan* sebagai penanganan *default*.

```
def chunk_document(doc: Dict[str, Any], md_file_path: Optional[str] = None) -> List[Dict[str, Any]]:
    doc_type = doc.get("type", "laporan")

    if doc_type == "peraturan":
        chunks = chunk_peraturan(doc)
    elif doc_type == "laporan_spbe":
        chunks = chunk_laporan_spbe(doc)
    elif doc_type == "pedoman_spbe":
        chunks = chunk_pedoman_spbe(doc)
    else:
        chunks = chunk_laporan(doc)

    if len(chunks) < MIN_JSON_CHUNKS_THRESHOLD and md_file_path:
        md_chunks = chunk_from_markdown(md_text, filename, doc_title)
        if len(md_chunks) > len(chunks):
            chunks = md_chunks
```

Gambar 4.6 Fungsi *chunk_document*

```
def preview_chunks(self, doc_id: str, use_figure_pipeline: bool = False) -> Dict[str, Any]:
    doc = self.get_document(doc_id)
    file_path = Path(doc["file_path"])

    extraction_result = extract_text_from_pdf(file_path, return_details=True)
    text = extraction_result.text
    doc_title = doc["document_title"] or Path(doc["original_filename"]).stem
    detected_type = detect_document_type(doc["original_filename"], text)

    doc_structure = parse_document(
        text=text,
        filename=doc["original_filename"],
        folder_hint=folder_hint,
    )
    structured_chunks = chunk_document(doc_structure, md_file_path=md_fallback_path)

    self.save_chunks(doc_id, chunks)
    self.update_document(
        doc_id,
        document_title=doc_title,
        doc_type=doc_type,
        chunk_count=len(chunks),
        status="previewed",
    )
```

Gambar 4.7 Fungsi *Preview Chunks*

Selain itu, berdasarkan Gambar 4.7 fungsi ini dirancang dengan tingkat ketahanan tinggi melalui mekanisme *fallback*. Dalam kondisi nyata di lapangan, ekstraksi PDF menjadi struktur data JSON yang rapi tidak selalu membuahkan hasil optimal,

khususnya pada dokumen hukum sejenisnya dengan tata letak yang rumit. Apabila sistem mendeteksi bahwa *chunk* berformat JSON yang dihasilkan terlalu sedikit atau tidak masuk akal, fungsi ini akan secara otomatis beralih memanfaatkan dokumen format Markdown yang dihasilkan oleh tools ekstraksi Marker sebagai acuan pemotongan alternatif. Skema berlapis ini menjamin bahwa sistem akan selalu berusaha menyelamatkan dan menyusun ulang konteks informasi sebaik mungkin sebelum disimpan ke dalam *vector database*.

IV.1.2.5 *Indexing* ke Qdrant dan BM25

Setelah pengguna menyetujui hasil preview dengan tombol simpan, *endpoint save_document* memanggil *DocumentManager.index_document* sesuai pada Gambar 4.8 Fungsi ini mengambil *chunk* yang sudah tersimpan dari tahap preview. Setiap *chunk* diubah menjadi embedding, lalu dikirim sebagai point ke Qdrant melalui *_upload_document_points*. Setelah itu, status dokumen berubah menjadi *indexed*, *chunk* ditandai sudah terindeks, dan BM25 dibangun ulang dari dokumen yang berstatus terindeks.

```
def index_document(self, doc_id: str) -> Dict[str, Any]:
    doc = self.get_document(doc_id)
    chunks = self.get_chunks(doc_id, limit=MAX_INDEX_CHUNKS)
    if not chunks:
        raise ValueError("No chunks to index. Run preview first.")

    embeddings = []
    for chunk in chunks:
        emb = self.generate_embedding(chunk["text"])
        embeddings.append(emb)

    uploaded_points = self._upload_document_points(doc_id, doc, chunks, embeddings)
    self.mark_chunks_indexed(doc_id)
    self.update_document(doc_id, status="indexed", chunk_count=len(chunks), processed_at=datetime.now().isoformat())
    self._rebuild_bm25_index()

    return {"doc_id": doc_id, "chunks_indexed": len(chunks), "status": "indexed"}
```

Gambar 4.8 Fungsi *index_document*

Payload Qdrant tidak hanya berisi vektor dan teks. Fungsi *_upload_document_points* juga menyertakan metadata seperti *doc_id*, *document_title*, *filename*, *doc_type*, *pasal*, *ayat*, *hierarchy*, *chunk_type*, dan informasi tabel. Metadata ini digunakan agar hasil retrieval tetap dapat dikembalikan ke sumber dokumen asal. Format payload metadata yang tersimpan ditampilkan pada Gambar 4.9

```

points.append({
  "id": str(uuid.uuid4()),
  "vector": emb,
  "payload": {
    "chunk_index": chunk_index,
    "text": chunk["text"],
    "context_header": chunk.get("context_header", ""),
    "document_title": doc["document_title"],
    "filename": doc["original_filename"],
    "doc_type": doc.get("doc_type", "other"),
    "pasal": chunk.get("pasal", ""),
    "ayat": chunk.get("ayat", ""),
    "hierarchy": chunk.get("hierarchy", ""),
    "doc_id": doc_id,
    "chunk_type": chunk.get("chunk_type", "text"),
    "table_context": chunk.get("table_context", ""),
  },
})

```

Gambar 4.9 *Payload Metadata*

Data yang telah diekstrak dan masuk ke dalam sistem AI memerlukan ruang untuk dievaluasi dan dikelola secara berkelanjutan. Untuk memfasilitasi hal tersebut, sistem menyediakan serangkaian endpoint API khusus pengelolaan, yaitu

1. *GET /api/documents/{doc_id}/chunks*, yang berfungsi untuk mengambil seluruh daftar potongan teks (*chunk*) dari sebuah dokumen untuk ditampilkan pada halaman detail antarmuka (*DocumentDetailView.vue*).
2. *PUT /api/documents/chunks/{chunk_id}* untuk memberikan fasilitas kepada pengelola sistem untuk memperbaiki kesalahan teks pada *chunk* secara langsung
3. *DELETE /api/documents/chunks/{chunk_id}* bertujuan untuk membuang *chunk noise* yang dirasa tidak dibutuhkan. Melalui alur ini, admin diberikan fleksibilitas untuk terus menyempurnakan kualitas data (data curation) yang akan dibaca oleh Large Language Model (LLM), tanpa perlu menghabiskan waktu komputasi untuk mengunggah dan memproses ulang dokumen dari awal.

IV.1.2.6 Sinkronisasi dan Penghapusan Dokumen

Selain manajemen di level *chunk*, sistem juga dibekali dengan fitur penghapusan penuh pada level berkas melalui fungsi *DocumentManager.delete_document*. Seperti yang ditunjukkan pada Gambar 4.10, penghapusan dokumen pada arsitektur RAG jauh lebih kompleks dibandingkan dengan sistem aplikasi CRUD konvensional.

```

def delete_document(self, doc_id: str) -> Dict[str, Any]:
    doc = self.get_document(doc_id)

    httpx.post(
        f"{qdrant_url}/collections/{collection_name}/points/delete",
        json={"filter": {"must": [{"key": "doc_id", "match": {"value": doc_id}}]}},
        timeout=30,
    )

    if doc.get("file_path"):
        file_path = Path(doc["file_path"])
        if file_path.exists():
            file_path.unlink()

    chunk_count = self.get_chunk_count(doc_id)
    self.db_delete_document(doc_id)
    self._rebuild_bm25_index()

    return {"doc_id": doc_id, "deleted_chunks": chunk_count, "status": "deleted"}

```

Gambar 4.10 Fungsi *delete_document*

Fungsi ini mengeksekusi penghapusan pada empat lapisan penyimpanan secara bersamaan, yaitu Qdrant, Disk, SQLite, dan BM2. Hal ini guna memastikan dokumen benar-benar bersih dan dikeluarkan secara permanen dari ekosistem retrieval. Sinkronisasi data dan rekonsiliasi pada skenario operasional tertentu sebagai contoh ketika sistem di-restart atau terjadi kehilangan database lokal bisa muncul anomali state, di mana Qdrant sebagai memori AI masih menyimpan data vektor, namun SQLite yang sebagai penampil tabel di UI dalam keadaan kosong.

Untuk mencegah sistem kehilangan kendali atas dokumennya, fungsi *sync_from_qdrant* dihadirkan sebagai mekanisme rekonsiliasi. Fungsi ini bekerja dengan cara membaca, menarik mundur seluruh point beserta *payload* metadata dari Qdrant, lalu mengelompokkannya berdasarkan identitas ID dokumen. Hasil pengelompokan tersebut lalu disuntikkan kembali ke dalam SQLite untuk membangun ulang tampilan manajemen di halaman frontend.

IV.1.3 Implementasi Autentikasi, Otorisasi, dan Audit Logging

Mekanisme autentikasi digunakan untuk memverifikasi identitas pengguna sebelum sistem memberikan akses. Mekanisme otorisasi digunakan untuk membatasi akses berdasarkan *role* pengguna. Sementara itu, pencabutan token dan audit logging digunakan untuk mengendalikan sesi pengguna serta mencatat aktivitas penting pada proses autentikasi.

Implementasi autentikasi pada sistem ini mengacu pada beberapa komponen utama, yaitu route autentikasi, pengelola JWT, layanan autentikasi, provider LDAP, penyimpanan token yang dicabut, pembatasan percobaan *login*, dependensi otorisasi, dan layanan audit. Seluruh komponen tersebut bekerja secara terintegrasi untuk mendukung proses *login*, *refresh* token, *logout*, pemeriksaan *role*, serta

pencatatan aktivitas autentikasi. Tabel 4.2 menjelaskan beberapa istilah mekanisme autentikasi dan otorisasi yang digunakan pada penelitian ini

Tabel 4.2 Ringkasan Mekanisme Autentikasi dan Otorisasi

Mekanisme	Tujuan	Hasil Implementasi
<i>Login</i>	Memverifikasi identitas pengguna	Sistem memeriksa kredensial melalui akun lokal, LDAP, atau mode hybrid
<i>Access token</i>	Memberikan akses sementara ke fitur sistem	Sistem membuat token akses setelah <i>login</i> berhasil
<i>Refresh token</i>	Memperpanjang sesi pengguna	Sistem menyediakan token pembaruan sesi dengan mekanisme rotasi
Pencabutan token	Menghentikan akses token tertentu	Sistem menolak token yang sudah dicabut atau digunakan saat <i>logout</i>
Otorisasi <i>role</i>	Membatasi akses fitur	Sistem memeriksa <i>role</i> pengguna sebelum mengizinkan akses fitur tertentu
Audit logging	Mencatat aktivitas autentikasi	Sistem mencatat percobaan <i>login</i> , <i>login</i> berhasil, <i>login</i> gagal, pembaruan token, dan <i>logout</i>

IV.1.3.1 Alur *Login* dan Pemilihan Provider

Alur autentikasi dimulai ketika pengguna mengirimkan email dan kata sandi ke endpoint *POST /api/auth/login*. Endpoint ini menerima kredensial pengguna dengan format *OAuth2* password form. Setelah permintaan diterima, sistem mencatat event *LOGIN_ATTEMPT*, mengambil alamat IP klien, lalu membentuk kunci rate limit berdasarkan kombinasi alamat IP dan *username*.


Mekanisme rate limiting digunakan untuk membatasi percobaan *login* yang gagal secara berulang. Jika pengguna melakukan percobaan *login* gagal melebihi batas yang telah dikonfigurasi, sistem mengembalikan respons *429 Too Many Requests* dan mencatat event *LOGIN_FAILURE* dengan alasan *rate_limited*. Mekanisme ini berfungsi sebagai pengendalian awal terhadap percobaan *login* yang tidak wajar.

Setelah pemeriksaan rate limit selesai, endpoint memanggil fungsi *authenticate_user()*. Fungsi ini bertugas memilih provider autentikasi berdasarkan konfigurasi *AUTH_PROVIDER*. Sistem mendukung tiga mode autentikasi, yaitu *local*, *ldap*, dan *hybrid*.

Pada mode *local*, sistem mencari akun pengguna pada tabel *users*. Setelah data pengguna ditemukan, sistem memverifikasi kata sandi yang dikirimkan pengguna

terhadap hash kata sandi yang tersimpan di database. Pada mode *ldap*, sistem melakukan bind dan pencarian pengguna melalui LDAP. Data direktori yang digunakan mencakup atribut seperti *memberOf*, *department*, *displayName*, *mail*, dan. Pada mode *hybrid*, sistem mencoba autentikasi LDAP terlebih dahulu. Jika konfigurasi mengizinkan, sistem dapat melakukan fallback ke autentikasi lokal.

Provider LDAP juga mendukung mekanisme *shadow user provisioning*. Mekanisme ini membuat atau memperbarui data user lokal berdasarkan hasil autentikasi LDAP. Data yang disimpan mencakup email, nama tampilan, *departemen*, *external ID*, *provider* autentikasi, dan *role* hasil pemetaan grup direktori. Dengan mekanisme ini, pengguna LDAP tetap memiliki representasi data pada database lokal aplikasi. Ilustrasi metode *login* digambarkan pada Gambar 4.11



Gambar 4.11 Proses *Login*

IV.1.3.2 Pembentukan *Access Token* dan *Refresh Token*


Setelah *login* berhasil, sistem membuat dua jenis token, yaitu *access* token dan *refresh* token. *Access* token digunakan sebagai bukti bahwa pengguna telah berhasil *login* dan berhak mengakses fitur tertentu dalam waktu terbatas. *Refresh* token digunakan untuk memperbarui *access* token tanpa meminta pengguna melakukan *login* ulang.

Access token memuat informasi dasar yang dibutuhkan sistem untuk mengenali pengguna. Informasi tersebut meliputi identitas pengguna, nama pengguna, *role*, unit kerja, sumber autentikasi, dan identitas sesi. Token ini juga memiliki waktu kedaluwarsa agar akses pengguna tidak berlaku tanpa batas.

Refresh token memiliki masa berlaku yang lebih panjang daripada *access* token. Token ini tidak dikirimkan sebagai data biasa pada respons sistem, tetapi disimpan dalam cookie. Cookie tersebut dikonfigurasi agar tidak mudah diakses dari sisi skrip browser. Dengan cara ini, *refresh* token digunakan sebagai mekanisme pendukung sesi tanpa menampilkan token secara langsung kepada pengguna. Berdasarkan fungsi dan karakteristiknya kedua token tersebut bisa dilihat pada Tabel 4.3

Tabel 4.3 Jenis Token pada Sistem

Jenis Token	Fungsi	Karakteristik
<i>Access</i> token	Memberikan akses sementara ke fitur sistem	Berumur pendek dan digunakan saat pengguna mengakses fitur terlindungi
<i>Refresh</i> token	Memperbarui <i>access</i> token	Berumur lebih panjang dan disimpan dalam cookie
Identitas sesi	Menghubungkan token dengan sesi pengguna	Digunakan untuk menjaga keterkaitan antara <i>login</i> dan pembaruan token




Gambar 4.12 Alur Pembentukan Token Setelah *Login*

IV.1.3.3 *Refresh* Token Rotation

Sistem menerapkan mekanisme *refresh* token rotation untuk memperbarui sesi pengguna. Mekanisme ini berjalan ketika *access* token pengguna sudah mendekati

kedaluwarsa atau tidak lagi dapat digunakan, tetapi *refresh* token masih valid. Pada proses ini, sistem membaca *refresh* token yang tersimpan pada cookie. Setelah itu, sistem memeriksa keaslian token, jenis token, masa berlaku token, dan status pencabutannya. Jika *refresh* token masih valid, sistem membuat *access* token baru dan *refresh* token baru.

Alur *refresh token* rotation bisa dilihat pada Gambar 4.13 berupa *refresh token* lama tidak digunakan kembali setelah proses pembaruan berhasil. Sistem mencatat token lama ke dalam daftar token yang telah dicabut. Dengan demikian, *refresh* token yang sudah dipakai tidak dapat digunakan ulang pada proses berikutnya.



Gambar 4.13 Alur *refresh* token rotation

Mekanisme rotasi ini membantu sistem mengendalikan siklus hidup sesi pengguna. Jika ada token lama yang digunakan kembali setelah proses pembaruan, sistem dapat menolaknya karena token tersebut sudah masuk daftar pencabutan.

IV.1.3.4 Pencabutan Token

Pencabutan token digunakan untuk menghentikan penggunaan token tertentu sebelum masa berlakunya selesai. Mekanisme ini dibutuhkan pada proses *logout* dan pembaruan *refresh* token. Token yang sudah dicabut tidak dapat digunakan kembali untuk mengakses sistem.

Sistem mencatat identitas token yang dicabut pada penyimpanan khusus. Data pencabutan token disimpan sampai token tersebut mencapai waktu kedaluwarsa alaminya. Setelah masa berlaku token habis, catatan pencabutan tidak lagi diperlukan karena token tersebut sudah tidak valid.

Pemeriksaan token dilakukan setiap kali pengguna mengakses fitur yang membutuhkan autentikasi. Sistem tidak hanya memeriksa apakah token valid, tetapi juga memeriksa apakah token sudah masuk daftar pencabutan. Jika token ditemukan pada daftar pencabutan, sistem menolak akses pengguna. Tabel 4.4 menjelaskan kondisi token beserta respon sistem terhadap kondisi tersebut.

Tabel 4.4 Kondisi Token dan Respons Sistem

Kondisi Token	Respons Sistem
Token valid dan belum dicabut	Akses dapat dilanjutkan sesuai <i>role</i> pengguna
Token kedaluwarsa	Akses ditolak dan pengguna perlu memperbarui sesi
Token sudah dicabut	Akses ditolak
Token tidak sesuai format	Akses ditolak
Token tidak memiliki identitas pengguna	Akses ditolak

Mekanisme ini membuat *logout* dan *refresh* rotasi token memiliki dampak langsung terhadap sesi pengguna. Token yang sudah dicabut tidak dapat digunakan kembali pada permintaan berikutnya.

IV.1.3.5 Otorisasi Berdasarkan *Role* Pengguna

Setelah identitas pengguna berhasil diverifikasi, sistem melakukan pemeriksaan *role*. Pemeriksaan ini menentukan apakah pengguna boleh mengakses fitur tertentu. Mekanisme ini disebut otorisasi berbasis *role*.


Role pengguna dapat berasal dari akun lokal atau hasil pemetaan grup LDAP. Jika pengguna berasal dari LDAP, sistem membaca grup keanggotaan pengguna pada direktori. Grup tersebut kemudian dipetakan menjadi *role* aplikasi. *Role* inilah yang digunakan sistem untuk menentukan hak akses.

Sistem membedakan akses untuk fitur umum dan fitur administratif seperti pada Tabel 4.5. Fitur umum dapat digunakan oleh pengguna yang sudah terautentikasi. Fitur administratif, seperti pengelolaan dokumen dan konfigurasi sistem, hanya diberikan kepada *role* tertentu.

Tabel 4.5 Contoh Pembatasan Hak Akses

Fitur Sistem	Pengguna yang Diizinkan	Tujuan Pembatasan
<i>Login</i> sistem	Pengguna terdaftar	Memastikan hanya pengguna valid yang dapat masuk
<i>Chatbot</i> pengetahuan SPBE	Pengguna terautentikasi	Membatasi akses <i>chatbot</i> pada pengguna internal atau pengguna yang diberi hak
Manajemen dokumen	Admin PUSDATIK	Mencegah perubahan dokumen oleh pengguna tanpa kewenangan
Penghapusan dokumen	Admin PUSDATIK	Menjaga integritas <i>knowledge base</i>

Pengaturan model atau konfigurasi	Admin PUSDATIK	Mencegah perubahan konfigurasi oleh pengguna biasa
-----------------------------------	----------------	--




Gambar 4.14 Alur pemeriksaan *role* pengguna

Gambar 4.14 menjelaskan bagaimana dua skenario mengenai *role* yang diizinkan dan ditolak dalam mengakses sistem. Jika *role* pengguna sesuai dengan kebutuhan fitur, sistem mengizinkan akses. Jika *role* tidak sesuai, sistem menolak akses dan memberikan status tidak berwenang. Dengan mekanisme ini, sistem dapat mencegah pengguna biasa melakukan perubahan pada bagian yang hanya boleh dikelola oleh admin.

IV.1.3.6 Logout

Logout digunakan untuk mengakhiri sesi pengguna. Proses ini penting karena pengguna perlu memiliki kendali untuk keluar dari sistem setelah selesai menggunakan aplikasi. Ketika pengguna melakukan *logout*, sistem memeriksa token yang sedang digunakan. Jika token masih valid, sistem mencatat token tersebut ke daftar token yang dicabut. Setelah itu, sistem menghapus *refresh* token yang tersimpan pada cookie. Dengan proses ini, sesi pengguna dihentikan dari sisi *access* token dan *refresh* token.



Gambar 4.15 Alur *logout* sistem

Gambar 4.15 menjelaskan mengenai prose *logout* pengguna dari sistem yang dimulai ketika setelah *logout* berhasil, pengguna tidak dapat lagi menggunakan token yang sama untuk mengakses fitur sistem. Jika pengguna ingin mengakses kembali sistem, pengguna harus melakukan *login* ulang. Proses *logout* juga dicatat pada audit log. Catatan ini berguna untuk mengetahui kapan pengguna keluar dari sistem dan membantu proses penelusuran aktivitas autentikasi.

IV.1.3.7 Audit Logging

Audit *logging* digunakan untuk mencatat peristiwa penting pada proses autentikasi. Mekanisme ini mendukung *traceability* karena setiap aktivitas utama dapat ditelusuri kembali berdasarkan waktu, pengguna, status, dan informasi pendukung lainnya. Pada proses autentikasi, sistem mencatat beberapa peristiwa utama, yaitu percobaan *login*, *login* berhasil, *login* gagal, pembaruan token, dan *logout*. Catatan tersebut membantu pengelola sistem memantau aktivitas pengguna dan mendeteksi kejadian yang tidak biasa, seperti percobaan *login* gagal secara berulang.

Audit log menyimpan informasi yang relevan dengan aktivitas autentikasi. Informasi tersebut mencakup jenis peristiwa, identitas pengguna, status aktivitas, alamat IP, waktu kejadian, dan detail tambahan. Data ini dapat digunakan sebagai dasar penelusuran jika terjadi masalah pada akses pengguna. Namun, audit logging pada penelitian ini dibatasi pada aktivitas autentikasi yang sudah diimplementasikan. Jenis peristiwa lain dapat tersedia pada sistem, tetapi tidak semuanya otomatis dicatat pada setiap proses. Oleh karena itu, pembahasan ini tidak menyatakan bahwa seluruh aktivitas aplikasi telah tercakup dalam audit logging.

Tabel 4.6 Event Audit pada Mekanisme Autentikasi

Event Audit	Kondisi Pencatatan	Tujuan
<i>LOGIN_ATTEMPT</i>	Pengguna mencoba <i>login</i>	Mencatat setiap percobaan masuk ke sistem
<i>LOGIN_SUCCESS</i>	<i>Login</i> berhasil	Mencatat keberhasilan autentikasi

<i>LOGIN_FAILURE</i>	<i>Login</i> gagal	Mencatat kegagalan autentikasi
<i>TOKEN_REFRESH</i>	Token berhasil diperbarui	Mencatat pembaruan sesi pengguna
<i>LOGOUT</i>	Pengguna keluar dari sistem	Mencatat penghentian sesi pengguna

Audit logging membuat sistem memiliki catatan operasional pada proses autentikasi. Catatan ini berguna untuk pemantauan, pemeriksaan insiden, dan evaluasi penggunaan sistem.

IV.1.4 Implementasi Autentikasi, Otorisasi, dan Audit Logging


RAG *engine* bekerja setelah pengguna berhasil masuk ke sistem dan mengirimkan pertanyaan melalui antarmuka *chat*. Pertanyaan tersebut diproses melalui beberapa tahapan sebelum jawaban ditampilkan kembali kepada pengguna. Tahapan tersebut dimulai dari pengelolaan sesi, pemahaman pertanyaan, pengambilan konteks dokumen, penyusunan *prompt*, pembuatan jawaban, sampai validasi sitasi.

Secara umum, alur RAG *engine* pada sistem ini dibagi menjadi tiga fase. Fase pertama adalah penanganan sesi percakapan. Fase kedua adalah retrieval *pipeline* untuk mencari konteks dari *knowledge base*. Fase ketiga adalah *generation pipeline* untuk menghasilkan jawaban menggunakan LLM.

Pembagian ini penting agar fungsi sistem dapat dijelaskan secara sistematis. Session handling memastikan percakapan pengguna tidak terputus. Retrieval *pipeline* memastikan sistem mengambil konteks yang relevan dari dokumen SPBE. *Generation pipeline* memastikan jawaban disusun berdasarkan pertanyaan pengguna, riwayat percakapan, dan konteks dokumen yang ditemukan.

IV.1.4.1 Arsitektur RAG Engine

Merupakan sebuah mekanisme inti yang menghubungkan pertanyaan pengguna, basis pengetahuan dokumen SPBE, dan model LLM yang ada, tahap ini dimulai dari pengguna yang pertama kali memberikan pertanyaan ke sistem yang diproses.




Gambar 4.16 Arsitektur RAG

Berdasarkan Gambar 4.16 proses sistem dalam menjawab pertanyaan pengguna secara fungsional dibagi menjadi tiga fase utama, yaitu Penerimaan Pertanyaan dan *Session Handling*, Proses Pencarian Dokumen (Retrieval Pipeline), dan Pembuatan Jawaban (LLM & Response).

IV.1.4.2 Penerimaan Pertanyaan dan Session Handling

Fase ini merupakan gerbang awal ketika pengguna mengirimkan pertanyaan, yaitu saat pertanyaan masuk, sistem mengecek apakah ini obrolan baru atau kelanjutan dari obrolan sebelumnya melalui *session_id*. Pada Gambar 4.17 jika pengguna baru pertama kali bertanya, sistem akan membuat sesi baru. Jika merupakan obrolan lanjutan, sistem akan memuat sesi yang sudah ada agar tidak kehilangan konteks obrolan sebelumnya. Setelah sesi dipastikan aman, pesan dari pengguna langsung dicatat ke dalam pangkalan data sebagai riwayat percakapan.




Gambar 4.17 Laman *chat* pengguna

Pada tahap ini, sistem juga membaca pengaturan penggunaan RAG. Jika RAG diaktifkan, sistem akan mencari konteks dari *knowledge base*. Jika RAG tidak diaktifkan, sistem dapat menghasilkan jawaban tanpa proses retrieval. Namun, untuk konteks penelitian ini, penggunaan RAG menjadi fokus utama karena sistem dirancang untuk menjawab berdasarkan dokumen SPBE.

IV.1.4.3 Klasifikasi Pertanyaan

Setelah pertanyaan diterima, sistem melakukan klasifikasi pertanyaan. Klasifikasi ini digunakan untuk mengenali jenis informasi yang dicari oleh pengguna. Hasil klasifikasi membantu sistem menentukan strategi retrieval dan format jawaban yang sesuai.

Pada Gambar 4.18, mulai dari *input* pengguna sistem akan mengelompokkan pertanyaan ke dalam beberapa kategori. Pertanyaan yang menyebut kata seperti pasal atau ayat dikategorikan sebagai pertanyaan regulasi. Pertanyaan yang menyebut tabel dikategorikan sebagai pertanyaan tabel. Pertanyaan yang menyebut indikator dikategorikan sebagai pertanyaan indikator. Jika pertanyaan tidak memiliki ciri khusus, sistem mengelompokkannya sebagai pertanyaan umum.



Gambar 4.18 Alur klasifikasi pertanyaan

Klasifikasi ini penting karena dokumen SPBE memiliki struktur yang beragam. Dokumen regulasi memiliki pasal dan ayat. Pedoman atau laporan dapat memiliki bab, subbab, tabel, indikator, atau matriks penilaian. Dengan klasifikasi awal, sistem dapat mengarahkan proses pencarian ke bagian dokumen yang lebih tepat.

Tabel 4.7 Kategori pertanyaan pada RAG

Kategori Pertanyaan	Ciri Pertanyaan	Tujuan Pemrosesan
Umum	Pertanyaan tidak menyebut struktur dokumen tertentu	Mencari konteks berdasarkan makna pertanyaan
Regulasi	Memuat kata pasal, ayat, perpres, permenpan, atau peraturan	Mengarahkan pencarian pada struktur hukum
Tabel	Memuat kata tabel atau nomor tabel	Mengarahkan pencarian pada bagian tabel
Indikator	Memuat kata indikator atau domain SPBE	Mengarahkan pencarian pada bagian indikator penilaian
Dokumen spesifik	Memuat nama atau nomor dokumen tertentu	Membatasi pencarian pada dokumen terkait

IV.1.4.4 Query Expansion

Setelah sistem mengenali jenis pertanyaan, sistem melakukan *query expansion*. Hal ini bertujuan untuk memperluas kata kunci pencarian agar sistem dapat menemukan konteks yang relevan meskipun pengguna memakai istilah singkat atau variasi istilah.

Proses ini dilakukan tanpa mengubah maksud asli pertanyaan. Sebagai contoh, jika pengguna menulis SPBE, sistem dapat menambahkan frasa Sistem Pemerintahan Berbasis Elektronik. Jika pengguna menyebut pasal tertentu, sistem mempertahankan nomor pasal tersebut agar pencarian tetap terarah. Jika pengguna menyebut tabel atau indikator, sistem menjaga informasi angka atau label yang disebutkan pengguna.

Query expansion diperlukan karena dokumen resmi sering menggunakan istilah lengkap, sedangkan pengguna dapat memakai singkatan atau istilah percakapan.


Dengan penyesuaian ini, peluang *retrieval* menemukan konteks yang tepat menjadi lebih besar. Contoh penggunaan query expansion yang diterapkan ke dalam sistem ini bisa dilihat pada Tabel 4.8

Tabel 4.8 Contoh *Query Expansion*

Pertanyaan Pengguna	Hasil Perluasan	Tujuan
Apa itu SPBE?	SPBE, Sistem Pemerintahan Berbasis Elektronik	Menemukan definisi pada dokumen resmi
Jelaskan Pasal 1 Perpres 95	Pasal 1, Perpres 95, Perpres Nomor 95 Tahun 2018	Mengarahkan pencarian pada regulasi tertentu
Apa indikator domain tata kelola?	indikator, domain tata kelola, SPBE	Mengarahkan pencarian pada bagian indikator
Jelaskan tabel tingkat kematangan	tabel, tingkat kematangan, evaluasi SPBE	Mengarahkan pencarian pada struktur tabel

IV.1.4.5 Hybrid Retrieval

Hybrid retrieval digunakan untuk mengambil konteks dari *knowledge base* dengan beberapa pendekatan pencarian. Pada sistem ini, *retrieval* tidak hanya bergantung pada kemiripan semantik. Sistem juga memanfaatkan pencarian berbasis kata kunci dan pencarian literal untuk menangani pertanyaan yang memiliki angka, istilah hukum, nomor pasal, nomor tabel, atau label indikator. Mekanisme *hybrid retrieval* bisa dilihat pada Gambar 4.19



Gambar 4.19 *Hybrid retrieval* pada RAG

Vector search digunakan untuk menemukan *chunk* berdasarkan kedekatan makna dengan pertanyaan pengguna. Metode ini membantu ketika pengguna memakai kalimat bebas atau istilah yang tidak sama persis dengan dokumen. BM25 digunakan untuk menemukan *chunk* berdasarkan kecocokan kata kunci. Metode ini membantu ketika dokumen memuat istilah yang jelas dan spesifik. Pencarian literal digunakan untuk menangani informasi yang perlu dicocokkan secara lebih langsung, seperti nomor pasal, nomor ayat, nomor tabel, atau indikator tertentu. Hal ini dijelaskan pada Tabel 4.9 mengenai fungsi dan kapan metode *retrieval* tersebut digunakan.

Penggunaan beberapa metode *retrieval* membuat sistem lebih fleksibel dalam menghadapi variasi pertanyaan. Namun, bagian ini tetap harus ditulis sebagai hasil implementasi, bukan hasil evaluasi. Pernyataan seperti “lebih akurat” perlu dibuktikan pada bagian *evaluation*.


Tabel 4.9 Metode *retrieval* pada RAG

Metode Retrieval	Fungsi	Contoh Kebutuhan
Vector search	Mencari konteks berdasarkan kemiripan makna	Pertanyaan umum atau pertanyaan dengan kalimat bebas
BM25	Mencari konteks berdasarkan kecocokan kata kunci	Pertanyaan dengan istilah teknis atau istilah resmi
Pencarian literal	Mencari konteks berdasarkan kecocokan eksplisit	Nomor pasal, ayat, tabel, atau indikator

IV.1.4.6 *Reciprocal Rank Fusion dan Reranking*

Setelah beberapa metode *retrieval* menghasilkan kandidat konteks, sistem menggabungkan hasil tersebut menggunakan mekanisme *fusion*. Alur pada Gambar 4.20 menjelaskan bahwa *Fusion* digunakan untuk menyatukan hasil pencarian dari vector search, BM25, dan pencarian literal agar sistem memiliki daftar kandidat konteks yang lebih terstruktur.

Pada tahap ini, kandidat konteks diberi skor berdasarkan posisi atau peringkatnya pada masing-masing metode pencarian. Kandidat yang muncul pada beberapa metode dapat memperoleh prioritas lebih tinggi karena dianggap lebih konsisten ditemukan dari beberapa jalur pencarian.




Gambar 4.20 Alur *reciprocal rank fusion* dan *reranking*

Setelah fusion, sistem melakukan reranking. Reranking digunakan untuk menyusun ulang kandidat konteks berdasarkan kesesuaian dengan pertanyaan pengguna. Sistem dapat memberi prioritas tambahan pada konteks yang memiliki metadata sesuai, seperti jenis dokumen, nomor regulasi, tahun, pasal, ayat, tabel, indikator, atau kategori dokumen. Tahap *fusion* dan *reranking* membantu sistem memilih konteks yang akan dikirimkan ke LLM.

IV.1.4.7 *Context Stitching* dan Penyusunan Sumber

Dokumen SPBE sering memiliki informasi yang panjang dan terstruktur. Ketika dokumen dipecah menjadi *chunk*, ada kemungkinan satu informasi penting tersebar pada beberapa *chunk* yang berdekatan. Oleh karena itu, sistem menerapkan *context stitching*.

Context stitching digunakan untuk mengambil *chunk* yang berada sebelum atau sesudah *chunk* utama dari dokumen yang sama. Tujuannya adalah menjaga konteks agar tidak terpotong. Pada Gambar 4.21 ditunjukkan alur penyusunan sumber, jika ada informasi yang berulang, sistem perlu mengurangi duplikasi agar konteks tetap ringkas. Setelah konteks disusun, sistem menyiapkan dua keluaran. Keluaran pertama digunakan oleh LLM sebagai konteks untuk membuat jawaban. Keluaran kedua digunakan oleh antarmuka pengguna sebagai daftar sumber rujukan. Daftar sumber ini memuat informasi seperti judul dokumen, bagian dokumen, metadata, skor kecocokan, dan cuplikan teks.



Gambar 4.21 lampiran dari penyusunan sumber jawaban

Penyusunan sumber penting karena *chatbot* penelitian ini tidak hanya dituntut menjawab pertanyaan, tetapi juga menunjukkan rujukan dokumen. Hasil pada penyusunan konteks tersebut bisa dilihat pada Tabel 4.10, rujukan tersebut membantu pengguna menelusuri dasar jawaban yang diberikan sistem.

Tabel 4.10 Hasil Penyusunan Konteks


Keluaran	Pengguna	Isi
Konteks untuk LLM	Model LLM	Potongan dokumen yang relevan dan telah disusun
Daftar sumber	Pengguna akhir	Judul dokumen, bagian dokumen, skor, dan cuplikan
Metadata konteks	Sistem	Identitas dokumen, jenis dokumen, pasal, ayat, tabel, atau indikator

IV.1.4.8 *Prompt Construction dan Generation oleh LLM*

Setelah konteks akhir diperoleh dari *pipeline retrieval*, sistem membangun *prompt* sebagai masukan untuk model LLM. *Prompt* tidak dibentuk dengan satu pola tetap, tetapi dipilih secara adaptif berdasarkan hasil klasifikasi pertanyaan. Pemilihan ini dilakukan agar instruksi yang diterima model sesuai dengan jenis pertanyaan pengguna.

Sistem menggunakan tiga varian *system prompt*. Pertama, *prompt* untuk pertanyaan bertipe tabel. *Prompt* ini mengarahkan model untuk membaca nilai tabel secara *literal* dan tidak melewati baris yang relevan. Kedua, *prompt* untuk pertanyaan bertipe regulasi, pasal, atau indikator. *Prompt* ini mengarahkan model agar menjawab berdasarkan teks dokumen dan mencantumkan kutipan yang sesuai.

Ketiga, *prompt* untuk pertanyaan umum. *Prompt* ini mengarahkan model untuk menyusun jawaban berbasis konteks dan menyertakan rujukan sumber.



Gambar 4.22 Alur *prompt construction* dan *generation* oleh LLM

Pada Gambar 4.22 dijelaskan bahwa input pengguna dari awal hingga masuk ke jawaban memerlukan beberapa tahapan. Pemilihan *prompt* adaptif diperlukan karena dokumen SPBE memiliki struktur informasi yang beragam. Pertanyaan tentang tabel membutuhkan perlakuan berbeda dengan pertanyaan tentang pasal. Pertanyaan tentang indikator juga perlu diarahkan agar model tidak menjawab terlalu umum. Dengan pemilihan *prompt* berdasarkan jenis pertanyaan, sistem dapat memberi instruksi yang lebih sesuai sebelum jawaban dibentuk oleh LLM.

Setelah *system prompt* dipilih, sistem menggabungkan konteks dokumen hasil retrieval ke dalam instruksi utama. Konteks tersebut diletakkan sebagai bagian referensi agar model memiliki dasar informasi saat menghasilkan jawaban. Selain itu, sistem juga memuat riwayat percakapan berdasarkan sesi pengguna. Riwayat ini disusun secara kronologis agar model dapat memahami kelanjutan dialog.

Sebelum pertanyaan akhir dikirimkan ke model, sistem menambahkan instruksi kualitas secara dinamis apabila konteks memuat kata kunci yang relevan dengan pertanyaan. Instruksi ini berfungsi sebagai pengarah tambahan agar model memperhatikan istilah penting yang ditemukan pada konteks. Pada pertanyaan bertipe tabel, instruksi ini juga membantu mencegah model menyatakan informasi tidak ditemukan ketika kata kunci terkait sebenarnya tersedia pada konteks.

Payload akhir untuk LLM terdiri dari *system prompt* adaptif, konteks referensi, riwayat percakapan, instruksi kualitas dinamis, dan pertanyaan pengguna. Sistem kemudian mengirimkan *payload* tersebut ke layanan *chat* Ollama untuk menghasilkan jawaban. Parameter inferensi dikonfigurasi dengan *temperature* rendah untuk mengurangi variasi keluaran, batas panjang jawaban, dan ruang konteks yang lebih besar agar *prompt*, riwayat, serta konteks dokumen dapat diproses dalam satu permintaan.

IV.1.4.9 Validasi Sitasi dan *Quality Report*

Tahap akhir pada RAG *engine* adalah validasi sitasi dan penyusunan *quality report*. Validasi sitasi digunakan untuk memeriksa apakah nomor rujukan dalam jawaban sesuai dengan daftar konteks yang tersedia. Jika model mencantumkan rujukan yang tidak ada pada konteks, sistem dapat menandainya sebagai peringatan.

Quality report digunakan untuk memberikan informasi operasional tentang jawaban yang dihasilkan. Informasi tersebut dapat mencakup jumlah sumber yang digunakan, status validasi sitasi, peringatan yang muncul, dan tingkat kepercayaan operasional berdasarkan aturan yang diterapkan sistem.

Bagian ini penting karena sistem *chatbot* berbasis RAG perlu memiliki mekanisme pemeriksaan setelah jawaban dihasilkan. Namun, validasi sitasi tidak sama dengan evaluasi kebenaran penuh. Validasi sitasi hanya menunjukkan apakah jawaban mengacu pada sumber yang tersedia.

Tabel 4.11 Komponen *quality report*

Komponen	Fungsi
Status sitasi	Menunjukkan apakah jawaban memuat rujukan
Jumlah sitasi	Menghitung jumlah rujukan yang muncul pada jawaban
Validitas sitasi	Memeriksa apakah nomor rujukan tersedia pada konteks
Peringatan	Menampilkan masalah seperti rujukan tidak valid
<i>Confidence</i> operasional	Memberikan status internal berdasarkan aturan validasi

IV.1.5 Implementasi Antarmuka Pengguna

Antarmuka pengguna diimplementasikan sebagai lapisan interaksi antara pengguna dengan sistem SPBE Asisten. Antarmuka ini menghubungkan fitur autentikasi, pengelolaan dokumen, *pipeline* RAG, model LLM, dan hasil jawaban yang ditampilkan kepada pengguna. Dengan adanya antarmuka, pengguna dapat menjalankan fungsi sistem tanpa berinteraksi langsung dengan *backend*, *database*, *vector database*, atau model LLM.

Antarmuka sistem terdiri atas beberapa halaman utama, yaitu halaman login, halaman beranda, halaman *chatbot*, daftar sesi percakapan, tampilan sumber referensi, halaman manajemen dokumen, halaman detail *chunk*, dan konfirmasi keluar dari sistem. Setiap halaman memiliki peran yang berbeda sesuai alur kerja sistem.

Pada sisi pengguna, antarmuka digunakan untuk masuk ke sistem, mengirim pertanyaan, menerima jawaban *chatbot*, melihat sumber referensi, mengelola sesi

percakapan, dan keluar dari sistem. Halaman *chatbot* menjadi komponen utama karena berfungsi sebagai titik masuk pertanyaan pengguna. Pertanyaan yang dikirim melalui halaman ini diteruskan ke RAG *engine* untuk diproses melalui retrieval, penyusunan konteks, *prompt construction*, *generation*, dan validasi sitasi.

Pada sisi administrator, antarmuka digunakan untuk mengelola dokumen yang menjadi sumber *knowledge base*. Administrator dapat mengunggah dokumen, memantau proses upload dan *indexing*, melihat daftar dokumen terindeks, membuka detail *chunk*, menjalankan sinkronisasi Qdrant, dan menghapus dokumen. Fitur ini penting karena kualitas *knowledge base* dipengaruhi oleh dokumen dan *chunk* yang tersedia di dalam sistem.

Tampilan sumber referensi juga menjadi bagian penting dari antarmuka. Setelah sistem menghasilkan jawaban, antarmuka menampilkan daftar sumber yang digunakan oleh RAG *engine*. Informasi tersebut membantu pengguna menelusuri dokumen asal dari jawaban yang diberikan. Dengan demikian, jawaban *chatbot* tidak berdiri sendiri, tetapi disertai rujukan yang dapat diperiksa kembali oleh pengguna.

Implementasi antarmuka pengguna pada penelitian ini tidak dibahas sebagai penilaian usability. Subbab ini hanya menjelaskan fungsi antarmuka dalam mendukung alur sistem. Penilaian terhadap kemudahan penggunaan, kualitas interaksi, dan pengalaman pengguna dibahas pada bagian *evaluation* menggunakan instrumen BUS-11. Tabel 4.12 berisi penjelasan mengenai tampilan antarmuka yang dibangun.

Tabel 4.12 Ringkasan Implementasi Antarmuka Pengguna

Komponen Antarmuka	Fungsi dalam Sistem
Halaman <i>login</i>	Memverifikasi akses sebelum masuk ke sistem
Halaman beranda	Menampilkan informasi awal dan akses menuju fitur utama
Halaman <i>chatbot</i>	Mengirim pertanyaan ke RAG <i>engine</i> dan menampilkan jawaban
Daftar sesi percakapan	Membuat sesi baru dan membuka riwayat percakapan
Toggle RAG	Mengaktifkan atau menonaktifkan penggunaan <i>knowledge base</i>
Pilihan model	Menentukan model LLM yang digunakan untuk <i>generation</i>
Sumber referensi	Menampilkan dokumen yang digunakan sebagai dasar jawaban

Komponen Antarmuka	Fungsi dalam Sistem
Manajemen dokumen	Mengunggah, memantau, dan mengelola dokumen knowledge base
Detail <i>chunk</i>	Meninjau isi <i>chunk</i> dan metadata dokumen
Sinkronisasi Qdrant	Menyelaraskan data dokumen dengan <i>vector database</i>
Konfirmasi keluar	Mengonfirmasi proses <i>logout</i> sebelum sesi dihentikan

IV.2 DEMONSTRATION

Tahap *demonstration* dilakukan untuk menunjukkan bahwa sistem SPBE Asisten yang telah dikembangkan dapat digunakan sesuai rancangan pada tahap design and development. Demonstrasi ini berfokus pada pembuktian bahwa fitur utama sistem dapat dijalankan pada lingkungan uji, baik dari sisi pengguna maupun administrator.

Tahap ini tidak dimaksudkan untuk menilai kualitas jawaban secara kuantitatif. Demonstrasi hanya menunjukkan bahwa alur utama sistem dapat berjalan sesuai fungsi yang dirancang. Penilaian terhadap kualitas retrieval, kesesuaian jawaban, validitas sitasi, waktu respons, pengujian JWT, dan usability dibahas pada tahap evaluation.

IV.2.1 Lingkungan Demonstrasi

Demonstrasi sistem dilakukan pada lingkungan uji yang disiapkan untuk menjalankan komponen utama SPBE Asisten. Seluruh komponen dijalankan agar alur dari pengelolaan dokumen sampai proses tanya jawab berbasis RAG dapat diamati secara langsung.

Lingkungan demonstrasi dibuat untuk merepresentasikan skenario penggunaan sistem oleh pengguna internal. Pada tahap ini, sistem belum dinyatakan sebagai sistem produksi. Oleh karena itu, hasil demonstrasi digunakan untuk menunjukkan kelayakan alur fungsional, bukan sebagai bukti akhir performa sistem. Untuk mendukung proses demonstrasi, sistem dijalankan menggunakan beberapa komponen perangkat keras dan perangkat lunak yang saling terintegrasi. Komponen tersebut digunakan untuk memastikan seluruh fitur sistem dapat berjalan dengan baik selama proses pengujian fungsional berlangsung. Tabel 4.13 menyajikan spesifikasi lingkungan demonstrasi yang digunakan untuk menjalankan sistem SPBE Asisten selama proses pengujian fungsional berlangsung.

Tabel 4.13 Lingkungan Demonstrasi Sistem

Komponen	Spesifikasi atau Keterangan
Processor	AMD Ryzen 7 2700 Eight-Core (16 CPUs), ~3.2GHz
Sistem operasi	Windows 11 Pro 64-bit
GPU	Nvidia GeForce GTX 1650 4GB
RAM	16 GB
Penyimpanan	1 TB HDD (SATA) + 250 GB SSD (NVME)

IV.2.2 Demonstrasi Pengguna

Demonstrasi pengguna dilakukan untuk menunjukkan alur penggunaan sistem dari sisi pengguna akhir. Alur ini dimulai dari proses login menggunakan email dan kata sandi yang valid. Setelah autentikasi berhasil, sistem mengarahkan pengguna ke halaman beranda. Pengguna kemudian membuka halaman *chatbot* untuk mengajukan pertanyaan terkait SPBE.

Pada saat pengguna mengirimkan pertanyaan, sistem menjalankan pipeline RAG untuk mengambil konteks dokumen yang relevan dari *knowledge base*. Setelah konteks diperoleh, sistem membangun prompt, menghasilkan jawaban menggunakan model LLM, dan menampilkan jawaban pada area percakapan. Jika sumber referensi tersedia, sistem menampilkan dokumen rujukan yang digunakan dalam proses *retrieval*.

Demonstrasi pengguna juga mencakup pengelolaan sesi percakapan. Pengguna dapat membuat sesi baru, membuka kembali sesi lama, dan melihat riwayat percakapan sebelumnya. Alur demonstrasi pengguna diakhiri dengan proses keluar dari sistem melalui tampilan konfirmasi keluar. Aktivitas demonstrasi pengguna tersebut disajikan pada Tabel 4.14.

Tabel 4.14 Demonstrasi Pengguna

Kode	Aktivitas Pengguna	Hasil yang Diamati
U-01	<i>Login</i> ke sistem	Sistem menampilkan halaman beranda
U-02	Membuka halaman <i>chatbot</i>	Sistem menampilkan antarmuka <i>chatbot</i>
U-03	Mengajukan pertanyaan SPBE	Sistem menampilkan jawaban <i>chatbot</i>
U-04	Melihat sumber referensi	Sistem menampilkan dokumen rujukan
U-05	Membuka sesi percakapan	Sistem menampilkan riwayat percakapan
U-06	Membuat sesi baru	Sistem membuat ruang percakapan baru
U-07	<i>Logout</i> dari sistem	Sistem menampilkan konfirmasi keluar

Hasil demonstrasi pengguna, sebagaimana pada Lampiran 3, menunjukkan bahwa sistem dapat menjalankan alur penggunaan sesuai dengan skenario yang telah

ditentukan. Pengguna berhasil melakukan *login* ke dalam sistem menggunakan kredensial yang valid dan diarahkan ke halaman beranda. Selanjutnya, pengguna dapat membuka halaman *chatbot* dan mengajukan pertanyaan terkait SPBE melalui antarmuka percakapan.

Sistem berhasil menjalankan *pipeline* RAG yang terdiri atas proses *retrieval* konteks dokumen, *generation* jawaban menggunakan model LLM, dan penampilan sumber referensi pada antarmuka pengguna. Jawaban *chatbot* berhasil ditampilkan beserta daftar referensi yang berasal dari *knowledge base*. Selain itu, pengguna juga dapat membuat sesi percakapan baru, membuka kembali riwayat percakapan sebelumnya, dan melakukan *logout* melalui halaman konfirmasi keluar dari sistem.

Dengan demikian, demonstrasi pengguna menunjukkan bahwa artefak yang dikembangkan telah dapat digunakan dalam alur tanya jawab berbasis RAG secara *end-to-end*, mulai dari autentikasi pengguna, pengiriman pertanyaan, pengambilan konteks dokumen, *generation* jawaban, hingga pengelolaan sesi percakapan dan *logout* sistem.

IV.2.3 Demonstrasi Administrator

Demonstrasi administrator dilakukan untuk menunjukkan proses pengelolaan *knowledge base* pada sistem SPBE Asisten. Demonstrasi dimulai dari halaman manajemen dokumen yang digunakan administrator untuk mengunggah dokumen SPBE sebagai sumber informasi *chatbot*.

Setelah dokumen dipilih, sistem menjalankan proses *upload*, ekstraksi teks, *chunking*, *embedding*, dan *indexing* ke dalam *vector database*. Selama proses berlangsung, sistem menampilkan status pemrosesan agar administrator dapat memantau tahapan *indexing* dokumen. Dokumen yang berhasil diproses akan ditampilkan pada daftar dokumen terindeks. Informasi yang ditampilkan mencakup nama dokumen, ukuran file, jumlah *chunk*, dan status indeks. Administrator juga dapat membuka detail *chunk* untuk melihat isi dokumen hasil pemrosesan beserta metadata yang tersimpan pada sistem.

Selain pengelolaan dokumen, sistem menyediakan fitur sinkronisasi Qdrant untuk menyelaraskan metadata dokumen dengan *vector database*. Administrator juga dapat menghapus dokumen dari *knowledge base* melalui dialog konfirmasi penghapusan. Untuk memastikan proses pengelolaan *knowledge base* berjalan dengan baik, dilakukan beberapa aktivitas demonstrasi dari sisi administrator. Aktivitas tersebut mencakup proses upload dokumen, *indexing*, peninjauan *chunk*, sinkronisasi data, hingga penghapusan dokumen dari sistem. Rangkaian aktivitas administrator selama demonstrasi disajikan pada Tabel 4.15.

Tabel 4.15 Demonstrasi Pengelolaan Knowledge Base

Kode	Aktivitas Administrator	Hasil yang Diamati
A-01	Membuka halaman manajemen dokumen	Sistem menampilkan area upload dan daftar dokumen
A-02	Mengunggah dokumen SPBE	Sistem menerima dokumen untuk diproses
A-03	Menjalankan pemrosesan dokumen	Sistem menampilkan tahapan upload, pemrosesan, dan indexing
A-04	Melihat daftar dokumen	Sistem menampilkan nama dokumen, jumlah <i>chunk</i> , dan status indeks
A-05	Membuka detail dokumen	Sistem menampilkan isi <i>chunk</i> dan metadata
A-06	Menghapus dokumen	Sistem menampilkan konfirmasi dan menghapus dokumen jika disetujui
A-07	Menjalankan sinkronisasi Qdrant	Sistem menyelaraskan data dokumen dengan vector database

Hasil demonstrasi administrator, sebagaimana pada Lampiran 3, menunjukkan bahwa sistem dapat menjalankan proses pengelolaan *knowledge base* sesuai dengan skenario yang telah ditentukan. Administrator berhasil membuka halaman manajemen dokumen dan mengunggah dokumen SPBE ke dalam sistem. Setelah dokumen diunggah, sistem menjalankan pipeline pemrosesan dokumen yang terdiri atas ekstraksi teks, *chunking*, *embedding*, dan *indexing* ke dalam *vector database*.

Dokumen yang berhasil diproses kemudian ditampilkan pada daftar dokumen terindeks beserta informasi jumlah *chunk* dan status indeks. Administrator juga dapat membuka detail *chunk* untuk meninjau isi dokumen dan metadata hasil pemrosesan sistem. Selain itu, fitur sinkronisasi Qdrant berhasil dijalankan untuk menyelaraskan metadata dokumen dengan *vector database*.

Demonstrasi juga menunjukkan bahwa administrator dapat menghapus dokumen dari *knowledge base* melalui dialog konfirmasi penghapusan. Dengan demikian, demonstrasi ini menunjukkan bahwa artefak yang dikembangkan telah dapat digunakan dalam proses pengelolaan *knowledge base* secara *end-to-end*, mulai dari upload dokumen sampai penghapusan dokumen dari sistem.

IV.3 EVALUATION

Tahap *evaluation* dilakukan untuk menilai artefak SPBE Asisten setelah sistem berhasil dirancang, dikembangkan, dan didemonstrasikan. Evaluasi ini bertujuan untuk mengetahui sejauh mana sistem memenuhi tujuan penelitian yang telah dirumuskan, yaitu menghasilkan jawaban berbasis dokumen SPBE, menerapkan mekanisme autentikasi berbasis JWT, dan menyediakan interaksi *chatbot* yang dapat diterima oleh pengguna.

Evaluasi pada penelitian ini dibagi menjadi tiga aspek utama. Pertama, evaluasi performa RAG menggunakan framework Retrieval-Augmented Generation Assessment atau RAGAS. Kedua, evaluasi keamanan autentikasi JWT berdasarkan skenario pengujian autentikasi, otorisasi, dan manajemen sesi. Ketiga, evaluasi kualitas interaksi pengguna menggunakan *Chatbot Usability Scale* atau BUS-11.

Tahap *evaluation* tidak lagi menjelaskan proses implementasi sistem. Bagian ini berfokus pada pengukuran hasil dari sistem yang telah dibangun. Dengan demikian, hasil evaluasi digunakan sebagai dasar untuk menjawab rumusan masalah penelitian dan menyusun simpulan pada Bab V.

IV.3.1 Dataset Evaluasi RAG

Dataset evaluasi RAG disusun untuk menguji kemampuan *chatbot* dalam menjawab pertanyaan terkait domain SPBE. Dataset berisi 40 pertanyaan yang mencakup definisi, regulasi, tata kelola, evaluasi SPBE, audit keamanan SPBE, penyelenggaraan sistem elektronik, dan informasi dari laporan evaluasi SPBE.

Setiap pertanyaan memiliki jawaban acuan dan sitasi dokumen. Jawaban acuan digunakan sebagai pembanding terhadap jawaban yang dihasilkan oleh *chatbot*. Sitasi dokumen digunakan untuk memastikan bahwa jawaban yang diharapkan memiliki dasar rujukan yang jelas.

Komponen lengkap dataset bisa dilihat pada Tabel 4.16, dataset ini digunakan sebagai dasar pengujian RAGAS. Untuk setiap pertanyaan, sistem menghasilkan jawaban *chatbot* dan mengambil lima konteks teratas dari knowledge base. Data yang digunakan dalam RAGAS terdiri atas pertanyaan, jawaban *chatbot*, konteks hasil retrieval, dan jawaban acuan.

Tabel 4.16 Ringkasan Dataset Evaluasi RAG

Komponen Dataset	Keterangan
Jumlah pertanyaan	40 pertanyaan
Bentuk data	Pertanyaan, jawaban acuan, dan sitasi dokumen
Domain pertanyaan	SPBE, regulasi, evaluasi SPBE, audit keamanan SPBE, dan penyelenggaraan sistem elektronik
Sumber jawaban acuan	Dokumen SPBE pada knowledge base
Jumlah konteks retrieval	Top-5 konteks untuk setiap pertanyaan
Penggunaan dataset	Evaluasi RAGAS

IV.3.2 Konfigurasi Evaluasi

Evaluasi RAG dilakukan menggunakan dataset pertanyaan dan jawaban acuan yang disusun dari dokumen domain SPBE. Dataset tersebut digunakan untuk menguji kemampuan sistem dalam menghasilkan jawaban berbasis dokumen. Setiap data uji terdiri atas pertanyaan, jawaban acuan, dan sitasi dokumen yang menjadi dasar jawaban.

Model yang digunakan oleh sistem *chatbot* adalah Qwen 3.5 4B yang dijalankan melalui Ollama. Model embedding yang digunakan adalah *Firqaqa/indo-sentence-bert-base*. Pada proses retrieval, sistem mengambil lima konteks teratas atau top-k sebesar 5. Konteks tersebut digunakan sebagai dasar penyusunan prompt sebelum jawaban dihasilkan oleh model LLM.

Pada evaluasi RAGAS, model evaluator yang digunakan adalah Llama 32B melalui Groq API. Model embedding yang digunakan untuk kebutuhan evaluasi tetap menggunakan *Firqaqa/indo-sentence-bert-base*. Penggunaan model evaluator yang berbeda dari model *chatbot* bertujuan untuk memisahkan peran model penghasil jawaban dan model penilai.

Evaluasi BUS-11 dilakukan terhadap 20 responden. Responden diminta menggunakan sistem terlebih dahulu melalui skenario yang telah ditentukan, kemudian mengisi kuesioner BUS-11. Data responden digunakan untuk menghitung skor faktor dan skor keseluruhan kualitas interaksi *chatbot*.

IV.3.3 Evaluasi Performa RAG Menggunakan RAGAS

Evaluasi performa RAG dilakukan untuk mengukur kualitas jawaban dan kualitas konteks yang diambil oleh sistem. Evaluasi ini menggunakan RAGAS karena framework tersebut dapat menilai hubungan antara pertanyaan, konteks hasil *retrieval*, jawaban *chatbot*, dan jawaban acuan.

Metrik yang digunakan pada evaluasi ini terdiri atas *faithfulness*, *answer relevancy*, *context precision*, dan *context recall*. *Faithfulness* digunakan untuk mengukur apakah klaim pada jawaban *chatbot* didukung oleh konteks yang diberikan. *Answer relevancy* digunakan untuk mengukur relevansi jawaban terhadap pertanyaan. *Context precision* digunakan untuk menilai apakah konteks yang diambil oleh sistem relevan dan berada pada urutan yang tepat. *Context recall* digunakan untuk menilai apakah konteks yang diambil sudah mencakup informasi yang diperlukan untuk menjawab pertanyaan.

Proses evaluasi RAGAS dilakukan dengan tahapan berikut. Pertama, sistem menerima pertanyaan dari dataset evaluasi. Kedua, sistem menjalankan *retrieval* dengan top-k sebesar 5. Ketiga, sistem menghasilkan jawaban menggunakan model

Qwen 3.5 4B melalui Ollama. Keempat, hasil jawaban, konteks retrieval, pertanyaan, dan jawaban acuan dikirim ke evaluator RAGAS. Kelima, evaluator menghasilkan skor pada 4 metrik utama. Pada Tabel 4.17 Dipaparkan Format data evaluasi yang dilakukan evaluasi menggunakan RAGAS

Tabel 4.17 Format Data Evaluasi RAGAS

Kolom	Isi
Question	Pertanyaan dari dataset evaluasi
Answer	Jawaban yang dihasilkan oleh chatbot
Contexts	Lima konteks teratas hasil retrieval
Ground truth	Jawaban acuan
Reference	Sitasi dokumen acuan
Context precision	Skor ketepatan konteks
Context recall	Skor kelengkapan konteks
Faithfulness	Skor kesesuaian jawaban terhadap konteks
Answer relevancy	Skor relevansi jawaban terhadap pertanyaan

IV.3.4 Hasil Evaluasi RAGAS Keseluruhan

Hasil evaluasi penuh terhadap 40 pertanyaan menunjukkan bahwa sistem memiliki performa yang kuat pada aspek pengambilan konteks. Hal ini terlihat dari skor *context recall* sebesar 0,9250. Skor tersebut menunjukkan bahwa sebagian besar informasi penting yang dibutuhkan untuk menjawab pertanyaan berhasil masuk ke konteks top-k.

Skor *context precision* sebesar 0,8193 menunjukkan bahwa konteks yang diambil sistem sudah cukup relevan, meskipun masih terdapat *noise* pada beberapa pertanyaan. Skor *faithfulness* sebesar 0,8352 menunjukkan bahwa sebagian besar jawaban didukung oleh konteks yang diberikan. Namun, skor *answer relevancy* sebesar 0,6659 menunjukkan bahwa jawaban sistem belum selalu langsung menjawab inti pertanyaan. Pada beberapa kasus, jawaban sudah benar, tetapi terlalu panjang atau menambahkan informasi tambahan yang tidak diminta.

Tabel 4.18 Hasil Evaluasi RAGAS

Metrik	Rata-rata	Jumlah Valid	Null	Interpretasi
<i>Context precision</i>	0,8193	40	0	Baik. Sebagian besar konteks relevan, tetapi masih ada noise pada beberapa pertanyaan

Metrik	Rata-rata	Jumlah Valid	Null	Interpretasi
<i>Context recall</i>	0,9250	40	0	Sangat baik. Fakta penting umumnya berhasil masuk ke konteks top-k
<i>Faithfulness</i>	0,8352	40	0	Baik. Jawaban cukup berbasis konteks, meskipun masih ada tambahan informasi pada beberapa jawaban
<i>Answer relevancy</i>	0,6659	40	0	Cukup. Jawaban sering benar, tetapi belum selalu ringkas dan tepat sasaran

Berdasarkan Tabel 4.18, sistem memiliki kekuatan utama pada *retrieval*. Nilai *context recall* yang tinggi menunjukkan bahwa sistem mampu menemukan konteks yang dibutuhkan untuk menjawab pertanyaan. Namun, nilai *answer relevancy* yang lebih rendah menunjukkan bahwa masalah utama berada pada tahap *generation*, terutama pada cara model menyusun jawaban agar lebih ringkas dan langsung menjawab pertanyaan.

IV.3.5 Hasil Evaluasi RAGAS per Pertanyaan

Hasil evaluasi per pertanyaan digunakan untuk melihat variasi performa sistem pada setiap data uji. Tabel ini membantu mengidentifikasi pertanyaan yang sudah dijawab dengan baik dan pertanyaan yang masih membutuhkan perbaikan.

Tabel 4.19 Hasil Evaluasi RAGAS per Pertanyaan

ID	Ringkasan Pertanyaan	CP	CR	Faith	AR
GT-001	Definisi Layanan SPBE	1,0000	1,0000	0,6000	0,8042
GT-002	Definisi Rencana Induk SPBE Nasional	1,0000	1,0000	0,7500	0,9398
GT-003	Pengertian Arsitektur SPBE	0,7000	1,0000	1,0000	0,9268
GT-004	Keamanan SPBE menurut Perpres 95 Tahun 2018	0,2500	1,0000	1,0000	0,9377
GT-005	Pengguna SPBE	1,0000	1,0000	1,0000	0,8751
GT-006	Prinsip pelaksanaan SPBE	0,8333	1,0000	1,0000	0,7846
GT-007	Tujuan Tata Kelola SPBE	0,6389	1,0000	0,7500	0,0000
GT-008	Unsur-unsur SPBE	1,0000	1,0000	1,0000	0,4332
GT-009	Lama penyusunan Arsitektur SPBE Nasional	0,2000	1,0000	0,3333	0,8639
GT-010	Definisi Audit TIK	1,0000	1,0000	0,8000	0,8545
GT-011	Pengertian Pemantauan SPBE	1,0000	1,0000	1,0000	0,9476

GT-012	Definisi Evaluasi SPBE	1,0000	1,0000	0,7500	0,8922
GT-013	Penilaian Dokumen	1,0000	0,0000	0,8000	0,4696
GT-014	Penilaian Visitasi	1,0000	1,0000	1,0000	0,9246
GT-015	Tujuan Pemantauan dan Evaluasi SPBE	0,9500	1,0000	1,0000	0,6656
GT-016	Tingkatan kematangan kapabilitas proses SPBE	1,0000	1,0000	1,0000	0,5705
GT-017	SPBE Tingkat 1 Rintisan	1,0000	1,0000	0,6667	0,9181
GT-018	Bobot Domain Layanan SPBE	1,0000	1,0000	0,9091	0,6472
GT-019	Predikat indeks 3,5 sampai kurang dari 4,2	1,0000	1,0000	0,7500	0,6825
GT-020	Predikat indeks di bawah 1,8	0,8875	1,0000	0,3333	0,6153
GT-021	Aplikasi SPBE Prioritas	0,0000	0,0000	0,7500	0,0000
GT-022	Target pengguna Aplikasi SPBE Prioritas	1,0000	1,0000	1,0000	0,5577
GT-023	Lembaga penyelenggara Aplikasi SPBE Prioritas	0,9500	1,0000	0,8000	0,6438
GT-024	Batas peluncuran Aplikasi SPBE Prioritas	1,0000	1,0000	1,0000	0,6195
GT-025	Audit Keamanan SPBE	0,8667	1,0000	0,6667	0,8704
GT-026	Objek Audit Keamanan SPBE	0,5833	1,0000	0,7500	0,7003
GT-027	Pelaksana Audit Keamanan SPBE	0,2000	1,0000	0,8333	0,6186
GT-028	Aspek bukti Audit Keamanan SPBE	0,7556	1,0000	1,0000	0,4762
GT-029	Konklusi akhir Audit Keamanan SPBE	0,9500	1,0000	0,5714	0,6044
GT-030	Penyelenggara Sistem Elektronik Lingkup Publik	1,0000	1,0000	0,6667	0,5943
GT-031	Sistem elektronik yang andal	1,0000	1,0000	0,7500	0,6414
GT-032	Sanksi administratif PSE	0,5000	1,0000	1,0000	0,4513
GT-033	Bentuk teknis pemutusan akses	0,9167	1,0000	0,8889	0,4471
GT-034	Manajemen SPBE di lingkungan BSSN	1,0000	1,0000	0,8000	0,7712
GT-035	Ruang lingkup SPBE BSSN	0,8333	1,0000	0,8571	0,5676
GT-036	Kewajiban Tim Koordinasi SPBE BSSN	0,7556	1,0000	1,0000	0,7932
GT-037	Audit Keamanan Internal di BSSN	1,0000	1,0000	1,0000	0,5837
GT-038	Laporan periodik LATIK Terakreditasi	1,0000	1,0000	1,0000	0,7380

GT-039	Domain skor evaluasi terendah nasional 2024	0,0000	0,0000	0,8000	0,5288
GT-040	Instansi pemerintah daerah dengan nilai tertinggi 2024	1,0000	1,0000	0,8333	0,6739

Keterangan: CP adalah *context precision*, CR adalah *context recall*, Faith adalah *faithfulness*, dan AR adalah *answer relevancy*.

Berdasarkan Tabel 4.19, sebagian besar pertanyaan memiliki *context recall* bernilai 1,0000. Hal ini menunjukkan bahwa sistem umumnya berhasil mengambil konteks yang memuat informasi penting. Namun, terdapat beberapa pertanyaan dengan skor rendah pada *context precision* atau *answer relevancy*. Kondisi ini menunjukkan bahwa sistem masih mengambil konteks tambahan yang kurang relevan atau menghasilkan jawaban yang terlalu luas dari pertanyaan.

IV.3.6 Pembahasan Hasil Evaluasi RAGAS

Hasil evaluasi menunjukkan bahwa sistem SPBE Asisten memiliki kemampuan *retrieval* yang kuat. Skor *context recall* sebesar 0,9250 menunjukkan bahwa sistem secara umum mampu menemukan informasi penting yang dibutuhkan untuk menjawab pertanyaan. Hal ini penting karena jawaban berbasis RAG sangat bergantung pada keberhasilan *retrieval* dalam mengambil konteks yang benar.

Skor *context precision* sebesar 0,8193 menunjukkan bahwa sebagian besar konteks yang diambil sudah relevan. Namun, skor ini masih lebih rendah dibanding *context recall*. Artinya, sistem mampu menemukan informasi penting, tetapi masih membawa beberapa konteks tambahan yang kurang relevan. Kondisi ini dapat terjadi karena top-k *retrieval* mengambil beberapa *chunk* sekaligus, termasuk *chunk* yang memiliki kemiripan kata tetapi tidak langsung menjawab pertanyaan.

Skor *faithfulness* sebesar 0,8352 menunjukkan bahwa jawaban sistem umumnya didukung oleh konteks yang diberikan. Namun, beberapa jawaban masih menambahkan informasi tambahan. Tambahan ini tidak selalu salah, tetapi dapat menurunkan skor *faithfulness* jika tidak sepenuhnya didukung oleh konteks yang digunakan pada evaluasi.

Skor *answer relevancy* sebesar 0,6659 menjadi nilai terendah dibanding metrik lainnya. Hasil ini menunjukkan bahwa jawaban sistem sering memiliki informasi yang benar, tetapi belum selalu langsung menjawab inti pertanyaan. Beberapa pertanyaan definisi, siapa, berapa, dan tujuan seharusnya dapat dijawab secara singkat. Jika sistem memberikan jawaban terlalu panjang, evaluator dapat menilai jawaban kurang relevan terhadap pertanyaan.

DAFTAR PUSTAKA

- [1] Y. Amazou, F. Tayalati, H. Mensouri, A. Azmani, dan M. Azmani, "Accurate AI Assistance in Contract Law Using Retrieval-Augmented Generation to Advance Legal Technology," *International Journal of Advanced Computer Science and Applications*, vol. 16, no. 2, 2025, doi: 10.14569/IJACSA.2025.01602113.
- [2] S. Vijayakumaran, M. Vimaladevi, R. Thangamani, N. Vibeesh, M. Chandru, dan S. V. Easwaramoorthy, "Revolutionizing Legal Access: An AI-Driven RAG Chatbot for Real-Time Judicial Insights," dalam *Proceedings - 3rd International Conference on Artificial Intelligence and Machine Learning Applications: Healthcare and Internet of Things, AIMLA 2025*, Institute of Electrical and Electronics Engineers Inc., 2025. doi: 10.1109/AIMLA63829.2025.11040439.
- [3] X. Fu dan C. Li, "Automating Plan Evaluation Using Agentic Large Language Models," *J. Plan. Educ. Res.*, 2025, doi: 10.1177/0739456X251372082.
- [4] J. Cui dkk., "Chatlaw: A Multi-Agent Collaborative Legal Assistant with Knowledge Graph Enhanced Mixture-of-Experts Large Language Model," Mei 2024, [Daring]. Tersedia pada: <http://arxiv.org/abs/2306.16092>
- [5] Kementerian Pendayagunaan Aparatur Negara dan Reformasi Birokrasi Republik Indonesia, *Laporan Evaluasi Sistem Pemerintahan Berbasis Elektronik (SPBE) Tahun 2024*. Jakarta, 2024. Diakses: 13 Januari 2026. [Daring]. Tersedia pada: <https://www.menpan.go.id/site/download/file/6985-laporan-pelaksanaan-evaluasi-spbe-tahun-2024>
- [6] Badan Siber dan Sandi Negara, "PERATURAN BADAN SIBER DAN SANDI NEGARA NOMOR 6 TAHUN 2021," 2021. Diakses: 14 Januari 2026. [Daring]. Tersedia pada: <https://peraturan.bpk.go.id/Download/167475/Peraturan%20BSSN%20Nomor%206%20Tahun%202021.pdf>
- [7] G. Papageorgiou, V. Sarlis, M. Maragoudakis, dan C. Tjortjis, "Hybrid Multi-Agent GraphRAG for E-Government: Towards a Trustworthy AI Assistant," *Applied Sciences (Switzerland)*, vol. 15, no. 11, Jun 2025, doi: 10.3390/app15116315.
- [8] Y. Gao dkk., "Retrieval-Augmented Generation for Large Language Models: A Survey," Mar 2024, [Daring]. Tersedia pada: <http://arxiv.org/abs/2312.10997>

- [9] C. Niu *dkk.*, “RAGTruth: A Hallucination Corpus for Developing Trustworthy Retrieval-Augmented Language Models,” Mei 2024, [Daring]. Tersedia pada: <http://arxiv.org/abs/2401.00396>
- [10] H. de Martim, “An Ontology-Driven Graph RAG for Legal Norms: A Structural, Temporal, and Deterministic Approach,” Sep 2025, [Daring]. Tersedia pada: <http://arxiv.org/abs/2505.00039>
- [11] S. Es, J. James, L. Espinosa Anke, dan S. Schockaert, “RAGAs: Automated Evaluation of Retrieval Augmented Generation,” dalam *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, Stroudsburg, PA, USA: Association for Computational Linguistics, 2024, hlm. 150–158. doi: 10.18653/v1/2024.eacl-demo.16.
- [12] M. Hindi, L. Mohammed, O. Maaz, dan A. Alwarafy, “Enhancing the Precision and Interpretability of Retrieval-Augmented Generation (RAG) in Legal Technology: A Survey,” *IEEE Access*, vol. 13, hlm. 46171–46189, 2025, doi: 10.1109/ACCESS.2025.3550145.
- [13] S. Borsci dan M. Schmettow, “Re-examining the *chatbot* Usability Scale (BUS-11) to assess user experience with customer relationship management *chatbots*,” *Pers. Ubiquitous Comput.*, vol. 28, no. 6, hlm. 1033–1044, Des 2024, doi: 10.1007/s00779-024-01834-4.
- [14] N. B. Aktaş, B. Şişman, dan S. Borsci, “Unleashing the potential of Turkish *chatbots*: a study on the validity and reliability of the bot usability scale,” *Univers. Access Inf. Soc.*, vol. 24, no. 3, hlm. 2467–2476, Agu 2025, doi: 10.1007/s10209-025-01211-9.
- [15] Kementerian Pendayagunaan Aparatur Negara dan Reformasi Birokrasi Republik Indonesia, “Peraturan Menteri Pendayagunaan Aparatur Negara dan Reformasi Birokrasi Republik Indonesia Nomor 59 Tahun 2020 tentang Pemantauan dan Evaluasi Sistem Pemerintahan Berbasis Elektronik,” Jakarta, Indonesia, Sep 2020.
- [16] R. M. I. R. Rusdy dan S. Flambonita, “PENERAPAN SISTEM PEMERINTAHAN BERBASIS ELEKTRONIK (SPBE) DI PEMERINTAH DAERAH UNTUK MEWUJUDKAN GOOD GOVERNANCE,” *Lex LATA*, vol. 5, no. 2, Jun 2023, doi: 10.28946/lexl.v5i2.2351.
- [17] L. Choirunnisa, T. H. C. Oktaviana, A. A. Ridlo, dan E. I. Rohmah, “Peran Sistem Pemerintah Berbasis Elektronik (SPBE) Dalam Meningkatkan Aksesibilitas Pelayanan Publik di Indonesia,” *Sosio Yustisia: Jurnal Hukum dan Perubahan Sosial*, vol. 3, no. 1, hlm. 71–95, Agu 2023, doi: 10.15642/sosyus.v3i1.401.
- [18] M. U. Hadi *dkk.*, “A Survey on Large Language Models: Applications, Challenges, Limitations, and Practical Usage,” 10 Juli 2023. doi: 10.36227/techrxiv.23589741.v1.

- [19] P. Lewis *dkk.*, “Retrieval-Augmented *Generation* for Knowledge-Intensive NLP Tasks,” 2020. [Daring]. Tersedia pada: <https://github.com/huggingface/transformers/blob/master/>
- [20] Z. Gao, H. Wang, Y. Zhou, W. Zhu, dan C. Zhang, “How Far Have We Gone in Vulnerability Detection Using Large Language Models,” Nov 2023, [Daring]. Tersedia pada: <http://arxiv.org/abs/2311.12420>
- [21] K. Guu, K. Lee, Z. Tung, P. Pasupat, dan M.-W. Chang, “REALM: Retrieval-Augmented Language Model Pre-Training,” 2020.
- [22] G. Izacard dan E. Grave, “Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering,” Apr 2021.
- [23] V. Karpukhin *dkk.*, “Dense Passage Retrieval for Open-Domain Question Answering,” Nov 2020. doi: 10.18653/v1/2020.emnlp-main.550.
- [24] Y. Wang, P. Li, M. Sun, dan Y. Liu, “Self-Knowledge Guided Retrieval Augmentation for Large Language Models.” [Daring]. Tersedia pada: <https://github.com/THUNLP-MT/SKR>.
- [25] Z. Jiang *dkk.*, “Active Retrieval Augmented *Generation*.” [Daring]. Tersedia pada: <https://github.com/>
- [26] M. Komeili, K. Shuster, dan J. Weston, “Internet-Augmented Dialogue *Generation*,” Long Papers. [Daring]. Tersedia pada: <http://parl.ai/projects/sea>
- [27] S. Ockerman *dkk.*, “Exploring Distributed Vector Databases Performance on HPC Platforms: A Study with Qdrant,” dalam *Proceedings of the SC '25 Workshops of the International Conference for High Performance Computing, Networking, Storage and Analysis*, New York, NY, USA: ACM, Nov 2025, hlm. 575–581. doi: 10.1145/3731599.3767404.
- [28] Y. A. Malkov dan D. A. Yashunin, “Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 42, no. 4, hlm. 824–836, Apr 2020, doi: 10.1109/TPAMI.2018.2889473.
- [29] J. Johnson, M. Douze, dan H. Jegou, “Billion-Scale Similarity Search with GPUs,” *IEEE Trans. Big Data*, vol. 7, no. 3, hlm. 535–547, Jul 2021, doi: 10.1109/TBDATA.2019.2921572.
- [30] Y. Luan, J. Eisenstein, K. Toutanova, dan M. Collins, “Sparse, Dense, and Attentional Representations for Text Retrieval,” *Trans. Assoc. Comput. Linguist.*, vol. 9, hlm. 329–345, Apr 2021, doi: 10.1162/tacl_a_00369.
- [31] O. Ram *dkk.*, “In-Context Retrieval-Augmented Language Models,” *Trans. Assoc. Comput. Linguist.*, vol. 11, hlm. 1316–1331, Nov 2023, doi: 10.1162/tacl_a_00605.
- [32] A. Bucko, K. Vishi, B. Krasniqi, dan B. Rexha, “Enhancing JWT Authentication and Authorization in Web Applications Based on User Behavior History,” *Computers*, vol. 12, no. 4, Apr 2023, doi: 10.3390/computers12040078.

- [33] A. Alkhulaifi dan E.-S. M. El-Alfy, "Exploring Lattice-based Post-Quantum Signature for JWT Authentication: Review and Case Study," dalam *2020 IEEE 91st Vehicular Technology Conference (VTC2020-Spring)*, IEEE, Mei 2020, hlm. 1–5. doi: 10.1109/VTC2020-Spring48590.2020.9129505.
- [34] E. Rushdy, W. Khedr, dan N. Salah, "FRAMEWORK TO SECURE THE OAUTH 2.0 AND JSON WEB TOKEN FOR REST API," *J. Theor. Appl. Inf. Technol.*, vol. 15, no. 9, 2021, [Daring]. Tersedia pada: www.jatit.org
- [35] I. Zulkarneev dan K. A. Basalay, "JSON Web Tokens Lifecycle-Based Threat Classification," dalam *International Conference of Young Specialists on Micro/Nanotechnologies and Electron Devices, EDM*, IEEE Computer Society, 2024, hlm. 1920–1924. doi: 10.1109/EDM61683.2024.10615042.
- [36] S. Dalimunthe, E. Hasri Putra, dan M. A. Fadhly Ridha, "Restful API Security Using JSON Web Token (JWT) With HMAC-Sha512 Algorithm in Session Management," *IT Journal Research and Development*, vol. 8, no. 1, hlm. 81–94, Des 2023, doi: 10.25299/itjrd.2023.12029.
- [37] S. Borsci *dkk.*, "The *Chatbot* Usability Scale: the Design and Pilot of a Usability Scale for Interaction with AI-Based Conversational Agents," *Pers. Ubiquitous Comput.*, vol. 26, no. 1, hlm. 95–119, Feb 2022, doi: 10.1007/s00779-021-01582-9.
- [38] A. F. Nugraha, H. Kabetta, I. K. S. Buana, dan R. B. Hadiprakoso, "Performance and Security Comparison of Json Web Tokens (JWT) and Platform Agnostic Security Tokens (PASETO) on RESTful APIs," dalam *Proceedings - 2023 IEEE International Conference on Cryptography, Informatics, and Cybersecurity: Cryptography and Cybersecurity: Roles, Prospects, and Challenges, ICoCICs 2023*, Institute of Electrical and Electronics Engineers Inc., 2023, hlm. 15–22. doi: 10.1109/ICoCICs58778.2023.10277377.
- [39] Akanksha dan A. Chaturvedi, "Comparison of Different Authentication Techniques and Steps to Implement Robust JWT Authentication," dalam *7th International Conference on Communication and Electronics Systems, ICCES 2022 - Proceedings*, Institute of Electrical and Electronics Engineers Inc., 2022, hlm. 772–779. doi: 10.1109/ICCES54183.2022.9835796.
- [40] Achmad Lutfan Aufar Hindami, "Implementasi Retrieval-Augmented Generation dan Guardrails dalam *Chatbot* Berbasis Open-Source Large Language Model untuk Layanan Informasi LSPro," Bogor, Agu 2025.
- [41] M. Park, H. Oh, E. Choi, dan W. Hwang, "LRAGE: Legal Retrieval Augmented Generation Evaluation Tool," Apr 2025, [Daring]. Tersedia pada: <http://arxiv.org/abs/2504.01840>
- [42] Z. Wang dan B. Yuan, "L-MARS: Legal Multi-Agent Workflow with Orchestrated Reasoning and Agentic Search," Sep 2025, [Daring]. Tersedia pada: <http://arxiv.org/abs/2509.00761>

- [43] K. Peffers, T. Tuunanen, M. A. Rothenberger, dan S. Chatterjee, “A design science research methodology for information systems research,” *Journal of Management Information Systems*, vol. 24, no. 3, hlm. 45–77, Des 2007, doi: 10.2753/MIS0742-1222240302.

LAMPIRAN

Surat Izin Penelitian

BADAN SIBER DAN SANDI NEGARA
POLTEK SSN

NOTA DINAS

Nomor : 30/PS/TA.01.02/01/2026

Yth. : Kepala Pusat Data dan Teknologi Informasi Komunikasi
Dari : Direktur Politeknik Siber dan Sandi Negara
Sifat : Biasa
Klasifikasi : Biasa
Lampiran : -
Hal : Permohonan Izin Penelitian Tugas Akhir dan Wawancara
Tanggal : 9 Januari 2025

1. Dasar:
 - a. Peraturan Badan Siber dan Sandi Negara Nomor 1 Tahun 2023 tentang Statuta Politeknik Siber dan Sandi Negara;
 - b. Peraturan Direktur Politeknik Siber dan Sandi Negara Nomor 4 Tahun 2024 tentang Pedoman Pelaksanaan Tugas Akhir;
 - c. Keputusan Direktur Politeknik Siber dan Sandi Negara Nomor 24 Tahun 2025 tentang Kalender Pendidikan Politeknik Siber dan Sandi Negara Tahun Akademik 2025/2026.
2. Sehubungan dengan dasar tersebut diatas, bersama ini disampaikan bahwa Taruna sebagai berikut bermaksud melakukan Penelitian Tugas Akhir dan Wawancara:

Nama : Muhammad Aqil Nuur Al-Farabi
NPM : 2221101817
Program Studi : Rekayasa Kriptografi
Bidang Minat : Rekayasa Perangkat Lunak Kriptografi
Tema Tugas Akhir : Implementasi Asisten Cerdas Berbasis SecureRAG dan Agentic AI dengan Kriptografi: Studi Kasus Peraturan SPBE di Pusdatik BSSN.
3. Terkait dengan hal tersebut, mohon kiranya taruna tersebut dapat diberikan izin untuk melakukan penelitian Tugas Akhir dimaksud.
4. Demikian disampaikan, atas perhatian dan kerjasamanya kami ucapkan terima kasih.



Dokumen ini telah ditandatangani secara elektronik menggunakan sertifikat elektronik yang diterbitkan oleh Balai Besar Sertifikasi Elektronik (BSrE), Badan Siber dan Sandi Negara

Transkrip Wawancara

Hari, tanggal : Rabu, 7 Januari 2026
 Narasumber : Pak Nur Kholis Gunawan
 Unit Kerja : Pusat Data dan Teknologi Informasi Komunikasi BSSN
 Pelaksanaan : *Zoom Meeting*

Identitas	Data Wawancara
Pewawancara	Assalamualaikum Pak Kholis. Terima kasih atas waktunya. Terkait rencana penelitian tugas akhir saya mengenai pengembangan <i>chatbot</i> di PUSDATIK, mohon izin untuk mengonfirmasi beberapa kebutuhan sistemnya. Sebagai awalan, mungkin bisa dijelaskan gambaran umum dan latar belakang dari proyek <i>chatbot</i> yang akan saya kembangkan ini, Mas?
Narasumber	Waalaikumsalam, . Latar belakangnya, waktu itu saat Aqil PKL di PUSDATIK (P22), kami melihat ada kebutuhan dari beberapa unit kerja di luar PUSDATIK untuk dibuatkan <i>chatbot</i> semacam <i>ChatGPT</i> yang <i>expert</i> terhadap suatu domain guna memberikan rangkuman konsep tertentu. Karena Aqil mengambil kompetensi <i>AI Retrieval-Augmented Generation</i> (RAG), kami meminta pengembangannya difokuskan pada domain Sistem Pemerintahan Berbasis Elektronik (SPBE) terlebih dahulu. Data SPBE ada di internal PUSDATIK dan sifatnya umum, sehingga harapannya jika sudah <i>expert</i> di SPBE, modelnya nanti bisa diimplementasikan ke domain lain.
Pewawancara	Baik, jadi fokus utamanya adalah <i>chatbot</i> berbasis AI RAG dengan tema SPBE. Lebih detail lagi terkait fungsionalitasnya Pak, pertanyaan semacam apa yang nantinya akan diajukan pengguna ke <i>chatbot</i> ini?
Narasumber	Harapannya <i>chatbot</i> ini menjadi alat bantu untuk <i>transfer knowledge</i> . Penilaian SPBE ke Kemenpan itu rutin setahun sekali dan sering melibatkan personel baru. Misalnya mereka bertanya, "Data dukung untuk indikator nomor 36 itu apa

	saja?", maka <i>chatbot</i> bisa memberikan ikhtisar dari data-data dukung tahun sebelumnya.
Pewawancara	Mengonfirmasi batasan sistemnya Pak, apakah ekspektasinya <i>chatbot</i> ini sampai bisa menyusun atau men- <i>generate</i> dokumen data dukung SPBE tersebut secara langsung, atau sekadar memberikan informasi prosedurnya saja?
Narasumber	Ekspektasi awalnya tidak sampai men- <i>generate</i> atau menyusun data dukung secara langsung. <i>Chatbot</i> hanya memberikan ikhtisar atau rekomendasi terkait data dukung yang diperlukan berdasarkan rekam jejak tahun-tahun sebelumnya.
Pewawancara	Izin bertanya terkait target penggunaanya, apakah mayoritas dari unit lain atau internal PUSDATIK? Lalu untuk implementasi model AI RAG-nya, apakah nantinya akan di- <i>hosting</i> di <i>server</i> internal PUSDATIK atau diperbolehkan memanggil API dari pihak luar?
Narasumber	Sebagian besar penggunaanya justru dari PUSDATIK sendiri, karena kebanyakan dari 47 indikator SPBE dilaksanakan oleh PUSDATIK. Terkait implementasi, jika sudah <i>production</i> , modelnya wajib di- <i>deploy</i> di <i>server</i> internal PUSDATIK. Kebijakan keamanan kita tidak memungkinkan untuk menggunakan model yang ada di luar.
Pewawancara	Jika wajib menggunakan <i>server</i> internal, bagaimana dengan mekanisme keamanannya? Apakah ada penerapan batasan <i>strict</i> tertentu serta mekanisme kontrol aksesnya, Pak?
Narasumber	Untuk keamanan detail di RAG, data sensitif di <i>vector database</i> pastinya harus diamankan atau dienkripsi. Untuk kontrol akses, pengguna harus <i>login</i> menggunakan token seperti JWT (<i>JSON Web Token</i>) yang terhubung dengan <i>Active Directory</i> . Aksesnya nanti dibedakan berdasarkan <i>role</i> pengguna dan dibatasi dengan <i>Policy Based Access Control</i> (PBAC) agar API-nya bersifat modular.
Pewawancara	Konsep pengguna, implementasi, dan keamanannya sudah sangat jelas. Terkait kendala teknis, dari pandangan Bapak, apa

	tantangan paling berat dalam pengembangan sistem ini yang harus saya antisipasi ke depannya?
Narasumber	Tantangan paling berat adalah menyusun agar sistem bisa memberikan rekomendasi yang akurat dan konsisten. Desain awal waktu PKL kemarin sudah jalan, tapi saat ditanya hal <i>basic</i> seperti "ada berapa domain di SPBE?", jawabannya masih kurang tepat. Ini mungkin karena model luar kurang fasih bahasa Indonesia. Saya sempat menyarankan pakai model lokal seperti Komodo, tapi kita terkendala saat <i>deploy</i> di lokal.
Pewawancara	Siap, Pak. Untuk memastikan masalah akurasi tersebut, nantinya saya berencana melakukan pengujian menggunakan <i>test case</i> berupa daftar pertanyaan umum. Terkait hal itu, agar pengujian tepat sasaran, untuk pengguna di PUSDATIK itu apakah ditujukan khusus untuk tim P22, P23, atau P24?
Narasumber	Penggunanya adalah personel yang dilibatkan dalam penilaian SPBE. Di P22 dan P23 personel yang mengumpulkan data dukung sering berubah-ubah setiap tahunnya dari si A ke si B. Nah, proses <i>transfer knowledge</i> antar personel baru dan lama inilah yang menjadi target utama sistem ini.
Pewawancara	Baik, informasinya sudah sangat jelas dan lengkap untuk dasar penelitian pengembangan <i>chatbot</i> ini. Terima kasih banyak atas waktu dan penjelasannya Pak Kholis. Ke depannya saya akan terus berkomunikasi untuk <i>update</i> progres selanjutnya. Wawancara ini saya tutup, Wassalamualaikum warahmatullahi wabarakatuh.
Narasumber	Waalaikumsalam warahmatullahi wabarakatuh. Sama-sama, Aqil.

Hari, tanggal : Senin, 9 Maret 2026
 Narasumber : Pak Nur Kholis Gunawan
 Unit Kerja : Pusat Data dan Teknologi Informasi Komunikasi BSSN
 Pelaksanaan : Zoom Meeting


Identitas	Data Wawancara
Pewawancara 1 (Aqil)	Assalamualaikum Pak Kholis, bagaimana kabarnya hari ini? Ini adalah sesi wawancara kedua kita sebagai tindak lanjut pasca-seminar proposal. Terdapat beberapa evaluasi dan pertanyaan dari tim penguji yang perlu kami konfirmasi kembali kepada pihak lokus.
Narasumber (Pak Kholis)	Walaikumsalam warahmatullahi wabarakatuh. Alhamdulillah sehat, Pak. Semoga Pak Budi dan Mas Aqil juga sehat.
Pewawancara 2 (Pak Budi)	Alhamdulillah. Kami memohon waktunya kembali karena ada tanggapan serius dari penguji setelah sidang terkait lokus penelitian ini. Penguji menaruh harapan besar agar sistem RAG ini bisa memberikan kontribusi nyata. Untuk mengonfirmasi, awalnya kita sepakat menjadikan PUSDATIK sebagai <i>pilot project</i> . Harapannya, sistem ini ke depannya bisa dicontoh dan diterapkan di unit kerja BSSN lainnya. Betul begitu arahnya, Pak Kholis?
Narasumber (Pak Kholis)	Betul, Pak. PUSDATIK menjadi lokus <i>pilot project</i> ini, khususnya untuk domain penilaian SPBE. Harapannya, jika sistem <i>chatbot</i> ini berhasil menguasai domain pengetahuan SPBE, ke depannya basis pengetahuannya bisa dikembangkan untuk menguasai domain proses bisnis lain di unit kerja BSSN.
Pewawancara 2 (Pak Budi)	Terkait evaluasi SPBE di PUSDATIK ini, apakah target pengguna <i>chatbot</i> ini murni hanya internal PUSDATIK, atau unit kerja lain juga bisa memanfaatkannya untuk mencari tahu soal data dukung?
Narasumber (Pak Kholis)	Penggunanya mencakup pihak di luar PUSDATIK juga. Penilaian SPBE melibatkan unit kerja lain, misalnya domain Arsip yang menjadi tanggung jawab S3, atau indikator Manajemen Pengetahuan yang diampu S2 (OSDM). Jadi, sebagian besar pengguna memang dari PUSDATIK, namun

	personel di unit kerja lain yang mengampu indikator spesifik tersebut juga sangat membutuhkannya.
Pewawancara 2 (Pak Budi)	Baik. Selanjutnya mengenai <i>input</i> sistem. Pertanyaan spesifik seperti apa yang paling diharapkan bisa dijawab dengan akurat oleh <i>chatbot</i> ini saat musim evaluasi SPBE?
Narasumber (Pak Kholis)	Berdasarkan pengalaman saya, terdapat 47 indikator pertanyaan di SPBE. Jika saya ditugaskan menyusun data dukung untuk indikator Kematangan Pengembangan Aplikasi, saya membutuhkan tiga informasi dasar dari sistem: 1. Apa sebenarnya yang dinilai dan diharapkan dari indikator tersebut beserta rujukan peraturannya? 2. Berapa nilai kematangan yang didapatkan BSSN pada evaluasi tahun sebelumnya? 3. Apa saja tambahan data dukung yang diperlukan tahun ini untuk meningkatkan nilai dari capaian tahun sebelumnya?
Pewawancara 2 (Pak Budi)	Untuk rujukan peraturan sifatnya publik. Namun, hasil penilaian tahun lalu dan rekomendasinya tentu berupa dokumen privat. Apakah kami bisa mendapatkan dokumen hasil evaluasi SPBE BSSN terbaru (misalnya 2024 atau sebelumnya)? Dokumen ini esensial agar sistem bisa mengetahui posisi BSSN saat ini dan memberikan rekomendasi yang tepat. Tentu sebelum dimasukkan ke model RAG, datanya akan kami anonimkan (<i>masking</i>).
Narasumber (Pak Kholis)	Bisa, Pak. Tahun 2025 kebetulan tidak ada penilaian, tetapi dokumen hasil penilaian beserta data dukung tahun 2024 dan sebelumnya bisa kami sediakan. Nanti sebelum dikirim, akan kami samarkan (<i>masking</i>) terlebih dahulu nama instansinya dari pihak kami untuk menjaga keamanan data internal.
Pewawancara 2 (Pak Budi)	Sangat baik, jadi dokumen aslinya tetap utuh pengetahuannya, hanya data instansinya yang dianonimkan. Terkait <i>output</i> , apakah ekspektasinya hanya berupa teks tanya-jawab, atau diharapkan bisa menghasilkan laporan dengan <i>template</i> khusus seperti PDF atau Word?

Narasumber (Pak Kholis)	BSSN sudah memiliki format standar penyusunan data dukung. Jika sistem ini bisa langsung menarik referensi dan menghasilkan dokumen rangkuman berformat Word sesuai <i>template</i> kami, itu akan sangat melampaui ekspektasi.
Pewawancara 2 (Pak Budi)	Apakah format dokumen Word ini mengacu pada aturan publik dari KemenPAN RB atau murni standar privat internal BSSN?
Narasumber (Pak Kholis)	Format tersebut adalah standar privat internal BSSN. Peraturan KemenPAN RB sebenarnya tidak mengatur baku bentuk data dukungnya. Namun dari pengalaman evaluasi, kami menyadari bahwa tim penilai lebih mudah dan lebih menyukai membaca sebuah dokumen Word yang berisi rangkuman dari dokumen peraturan aslinya. Menyertakan rangkuman ini terbukti memberikan nilai evaluasi yang lebih baik dibandingkan hanya melampirkan file PDF aturan utuh yang sangat panjang.
Pewawancara 2 (Pak Budi)	Sangat mencerahkan. Sebagai tindak lanjut teknis, ada tiga poin krusial: 1. Mas Aqil akan menyusun daftar sekitar 30 pertanyaan tolak ukur (<i>benchmark</i>) yang wajib bisa dijawab sistem. Kami mohon bantuan Pak Kholis nanti untuk memvalidasinya. 2. Kami menunggu dokumen hasil penilaian 2024 yang sudah di-<i>masking</i>. 3. Kami juga membutuhkan <i>template</i> format laporan Word tersebut sebagai rujukan <i>output</i> sistem. Silakan Mas Aqil jika ada pertanyaan tambahan.
Narasumber (Pak Kholis)	Baik, Pak. Nanti kami siapkan dokumen penilaian tahun 2024 beserta data dukungnya, dan kami <i>masking</i> sebelum dikirimkan ke Mas Aqil.
Pewawancara 1 (Aqil)	Terima kasih, Pak Budi. Izin melanjutkan pertanyaan, Pak Kholis. Mengingat penggunaannya lintas unit kerja, kira-kira berapa estimasi jumlah pengguna aplikasi <i>chatbot</i> ini nantinya? Ini berkaitan dengan rencana penyebaran kuesioner penilaian kepuasan sistem di tahap akhir penelitian.

Narasumber (Pak Kholis)	Kita estimasikan saja dari jumlah 47 indikator pertanyaan SPBE tadi. Biasanya satu personel secara spesifik ditugaskan untuk menyusun data dukung satu indikator. Jadi, paling tidak akan ada sekitar 47 personel yang aktif menggunakan aplikasi ini selama masa penyusunan data dukung, yang biasanya berlangsung sekitar 1-2 bulan.
Pewawancara 1 (Aqil)	Baik. Untuk memvalidasi keakuratan jawaban <i>chatbot</i> nanti, apakah pengujiannya cukup dilakukan di lingkup internal PUSDATIK saja, atau perlu divalidasi juga oleh personel dari unit kerja lain?
Narasumber (Pak Kholis)	Untuk tahap awal, validasi oleh personel PUSDATIK dengan kemampuan setara dalam penyusunan laporan evaluasi SPBE dibandingkan unit kerja lain saja sudah cukup.
Pewawancara 1 (Aqil)	Siap, Mas. Pertanyaan terakhir, menyinggung wawancara kita sebelumnya mengenai mekanisme pengamanan <i>backend</i> menggunakan JWT (<i>JSON Web Token</i>). Bagaimana gambaran strategi penerapannya terkait manajemen akses (<i>role-based access control</i>) di arsitektur sistem PUSDATIK?
Narasumber (Pak Kholis)	Prinsip dasarnya, JWT digunakan untuk membatasi <i>request</i> ke <i>backend</i> berdasarkan hak akses masing-masing pegawai. Saat pegawai melakukan <i>login</i> di sisi <i>frontend</i> , layanan autentikasi (<i>authentication service</i>) akan menerbitkan token yang mengandung identitas (<i>identifier</i>) pegawai tersebut. Token ini wajib disematkan di dalam setiap <i>request</i> yang dikirim. <i>Backend</i> kemudian akan mengecek dan memvalidasi token tersebut untuk memastikan apakah <i>identifier</i> pegawai terkait memiliki hak (<i>role</i>) untuk meminta data atau menjalankan perintah tersebut.
Pewawancara 1 (Aqil)	Dapat dipahami dengan jelas, Pak. Dari daftar pertanyaan saya sudah cukup. Saya kembalikan ke Pak Budi.
Pewawancara 2 (Pak Budi)	Dari kami berdua dirasa sudah sangat cukup untuk menggali kebutuhan sistem ini. Terima kasih banyak atas waktu dan wawasannya, Pak Kholis. Harapannya, <i>output</i> dari tugas akhir ini benar-benar bisa diimplementasikan dan bermanfaat bagi BSSN, khususnya PUSDATIK.


Narasumber (Pak Kholis)	Sama-sama, Pak. Amin. Jika ke depannya perlu diskusi lebih lanjut mengenai data dukung atau arsitekturnya
Pewawancara 1 (Aqil)	Baik, Pak Kholis. Terima kasih banyak atas bantuannya. Wassalamualaikum warahmatullahi wabarakatuh.
Narasumber (Pak Kholis)	Waalaikumsalam warahmatullahi wabarakatuh.




Gambar 1. Demonstrasi Login Pengguna




Gambar 2. Demonstrasi Halaman Beranda



Gambar 3. Demonstrasi Halaman *Chatbot*




Gambar 4. Demonstrasi Pertanyaan Pengguna kepada *Chatbot*




Gambar 5. Demonstrasi Jawaban *Chatbot*



Gambar 6. Demonstrasi Jawaban dengan Sumber Referensi



Gambar 7. Demonstrasi Pengelolaan Sesi Percakapan




Gambar 8. Demonstrasi Konfirmasi Keluar dari Sistem


DOKUMEN TERSEDIA
Daftar sumber yang dapat digunakan sistem untuk menelusuri rujukan SPBE. 10 dokumen

NAMA DOKUMEN	UKURAN	KONTEKS	STATUS	AKSI
peraturan bssn no 8 tahun 2024 peraturan	529.8 KB	217	Terindeks	Detail Hapus
PERKA BSSN NOMOR 2 TAHUN 2023 peraturan	1.9 MB	445	Terindeks	Detail Hapus
20250313_Laporan_Pelaksanaan_Evaluasi_SPBE_2024.pdf laporan_spbe	0 B	594	Terindeks	Detail Hapus
LAPORAN EVALUASI SPBE KemenpanRB 2023.pdf audit	0 B	337	Terindeks	Detail Hapus
PP Nomor 71 Tahun 2019.pdf peraturan	0 B	324	Terindeks	Detail Hapus
Perpres Nomor 95 Tahun 2018.pdf peraturan	0 B	147	Terindeks	Detail Hapus
Perpres Nomor 82 Tahun 2023.pdf peraturan	0 B	43	Terindeks	Detail Hapus
Permenpan RB Nomor 59 Tahun 2020.pdf peraturan	0 B	292	Terindeks	Detail Hapus
peraturan-bssn-no-8-tahun-2024.pdf peraturan	0 B	114	Terindeks	Detail Hapus

Gambar 9. Demonstrasi Halaman Manajemen Dokumen




Gambar 10. Demonstrasi Proses Upload dan Indexing Dokumen



Gambar 11. Demonstrasi Daftar Dokumen Terindeks



Gambar 12. Demonstrasi Detail Dokumen dan *Chunk*



Gambar 13. Demonstrasi Konfirmasi Hapus Dokumen

DAFTAR RIWAYAT HIDUP

Nama : Muhammad Aqil Nuur Al-Farabi
Tempat/tanggal lahir : Nganjuk/ 21 Januari 2003
Riwayat pendidikan : 1. TK Al-Huda Kota Kediri 2009
2. SDI Al-Huda Kota Kediri 2015
3. MTsN 2 Kota Kediri 2018
4. MAN 2 Kota Kediri 2021